

구조 조건부 확산 모델을 위한 주파수 다이얼

익명 제출

Abstract

구조 조건부 확산 어댑터는 하나의 동작점에서 학습된다. Canny 엣지, 깊이 맵, 스케치 — 각각은 출력이 조건을 얼마나 따를지를 고정하고, 그 균형을 옮기려면 다시 학습해야 한다. 우리는 조건의 정보량을 무작위화해 어댑터 하나를 학습한다. 차단 반경 r 을 샘플마다 뽑는 고주파 통과 필터를 쓰고, 추론 시 r 을 다이얼로 되읽는다. FFHQ-512에서 구조 순응도는 $r=0.05$ 의 0.7469에서 $r=0.7$ 의 0.1110까지 내려가고 표본 다양성은 0.3126에서 0.4334까지 올라가며, FID는 전 구간에서 52.77와 57.40 사이에 머문다. 대신 어댑터 세기를 줄이면 같은 구조 순응도에 도달하는데 FID를 최대 104.95까지 쓴다. 주파수 다이얼의 53.97와 비교하면 두 손잡이는 대체재가 아니다.

구현 과정에서 두 가지를 발견했다. 냉동 SD VAE는 어댑터가 읽기 전에 고주파 조건을 파괴한다. 인코딩-디코딩 왕복 후 남은 조건은 $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700에 불과하다. 그리고 주입 위치가 용량을 압도한다. 디코더 스킵 연결에 얹은 잔차가 구조 신호의 0.5370를 나르는 반면 교차 어텐션 주입은 0.2112에 그치고, 어댑터 폭을 네 배로 늘려도 그보다 훨씬 적게 얻는다. 학습 파라미터는 6,611,469개로 ControlNet의 55분의 1이다.

1 서론

ControlNet [34]과 그 후속 연구들 [12, 17, 24, 37]은 조건부 제어를 풀고 그대로 굳혔다. Canny 엣지로 학습한 어댑터는 Canny 엣지를 따르고, 깊이로 학습한 어댑터는 깊이를 따른다. 얼마나 따를지는 학습된 가중치의 성질이므로, 같은 스케치를 더 느슨하게 반영하고 싶은 작가는 다른 체크포인트를 고르거나 가진 것이 학습된 대로 받아들여야 한다.

우리는 모델이 얼마나 귀 기울이는지가 아니라 조건 자체를 바꾼다. 조건은 정규화된 차단 반경 r 의 방사형 고주파 통과 필터를 거친 이미지다. $r=0$ 에서 모델은 회색조 이미지를 받고 과제는 색복원이 된다. r 이 커질수록 필터가 스펙트럼을 더 많이 제거해 $r=1$ 에서는 거의 남지 않는다. FFHQ에서 실측하면 차단 반경 0.05만 되어도 스펙트럼 에너지의 97.5%가 사라진다. 학습은 r 을 샘플마다 뽑으므로 가중치 하나가 전 구간을 보고, r 은 추론 시 파라미터가 된다.

기여는 다음과 같다.

- 제어 다이얼. 어댑터 하나가 구조 순응도 0.7469에서 0.1110까지를 담당하며 FID는 52.77와 57.40 사이로 평평하다 (4.1절).
- 이 다이얼이 어댑터 세기를 다시 스케일한 것이 아니라는 근거. 구조 순응도를 맞추면 세기 손잡이는 FID 104.95을 쓰고 주파수 손잡이는 53.97를 쓴다 (4.2절).
- 고주파 조건이 냉동 VAE를 얼마나 통과하는지에

대한 측정. 잠재 공간 조건화가 희소한 구조에서 실패하는 이유를 설명한다 (4.3절).

- 주입 위치가 어댑터 용량이나 수용 영역보다 중요함을 보이는 통제 비교 (4.4절).

2 관련 연구

조건부 제어. 텍스트-이미지 확산 모델 [6, 18, 26, 27, 29]은 ControlNet [34]으로 공간 제어가 가능해졌다. 인코더를 복제하고 0 합성곱으로 잔차를 주입하는 방식이다. T2I-Adapter [17]는 작은 특징 추출기로 같은 일을 하고, IP-Adapter [32]는 이미지 프롬프트를 위한 분리형 교차 어텐션을 더하며, GLIGEN [13]은 박스로 생성을 접지한다. Uni-ControlNet [37]과 Uni-Control [24]은 여러 조건 유형을 한 모델에 담고, ControlNet++ [12]는 생성된 이미지에서 일관성 루프를 단는다. 이들 모두 조건 유형을 고정하고, 그와 함께 출력이 얼마나 따를지도 고정한다. 동작점이 학습된 가중치의 성질이 되는 것이다. 우리의 차단 반경은 가중치 하나에서 추론 시 그 점을 옮긴다.

트랜스포머 백본에서의 효율적 제어. 백본이 UNet에서 확산 트랜스포머 [1, 20]로 옮겨가면서 제어도 복제 인코더에서 경량 모듈로 이동했다. ControlNeXt [21]는 병렬 분기를 없애고, OminiControl [30]은 백본 자체를 조건 처리기로 재사용하며, EasyControl [36]과 NanoControl [15]은 LoRA [7] 계열 모듈로 훨씬 적은 파라미터에서 조건을 주입한다. 조건이 어디로 들어가야 하는지도 최근 연구 대상이다. Laytrol [9]은 레이아웃 제어에서 사전학습 지식 보존을, PixelControl [14]은 조건 충실도를, Zhou et al. [38]은 다중 조건 DiT의 중복 어텐션 제거를 다룬다. 우리의 주입 위치 비교(4.4절)는 UNet 백본에서 양립하는 결론에 도달한다. 위치가 용량을 압도한다.

확산 모델에서의 주파수. 주파수 분해는 확산 연구에서 대개 조건이 아니라 모델 자신의 신호에 대한 개입으로 나타난다. FreeU [28]는 스킵과 백본 특징을 학습 없이 스펙트럼 상에서 재조정하고, FreSca [8]는 노이즈 예측의 주파수 대역을 스케일하며 우리처럼 에너지 기반 차단을 쓴다. DeCo [16]는 픽셀 공간 확산에서 주파수를 분리하고, FeRA [33]는 주파수 에너지로 적응을 라우팅한다. FOCUS [31]는 테스트 시 적응을 위해 학습된 주파수 사전으로 역과정을 조건화한다. 취지상 가장 가까운 것은 Prasain [23]로, 지도-위성 합성에서 엣지 맵 대신 웨이블릿 대역으로 조건화한다. 그러나 어느 연구도 학습 중 조건의 대역폭을 무작위화해 그 대역이 추론 시 제어가 되게 하지는 않으며, 그것이 우리가 다루는 기제다.

구조 보존. StructDiff [3]는 구조 보존형 공간 제어 생성을 목표로 하고, 스케치 조건 파이프라인은

오래전부터 엣지 맵을 구조 전달자로 써 왔다. 우리 조건은 고정된 추출기가 아니라 연속체이며, 그것이 다이얼을 가능하게 한다.

학습과 평가. 분류자 없는 유도 [5] 드롭아웃과 Min-SNR 손실 가중 [2]으로 학습하고, FID [4]를 clean-FID 프로토콜 [19]로, LPIPS [35]와 CLIP 점수 [25]를 BLIP [11] 캡션이 달린 FFHQ [10]에서 평가한다. SDXL과 SD3 [1, 22]가 다음 백본으로 자연스럽다.

3 방법

조건. 이미지 x 를 회색조로 바꾸고 2차원 FFT를 취한 뒤 반지름 $r \cdot \min(H, W)/2$ 원판 안의 모든 주파수를 0으로 만들고 역변환한 다음 $[0, 1]$ 로 최소-최대 정규화한다. 정규화는 의도적이다. 필터 응답의 절대 크기를 없애 모델이 공간 통계만으로 구조 밀도를 추론하게 만든다. r 이 존재하지 않는 손그림을 추론 시 쓸 수 있는 이유가 여기에 있다. 그림 1는 마스크와 마스크된 스펙트럼, 그리고 그 결과 조건을 전 구간에 걸쳐 나란히 보여준다.

조건 인코더. 스트라이드 합성곱 스텐이 512^2 조건 이미지를 직접 읽어 $8 \times$ 줄인다. 조건을 냉동 VAE로 인코딩하지 않는다. 이유는 4.3절에 있다.

주입. 인코더 특징은 UNet에 두 곳으로 들어간다. 0으로 초기화된 1×1 헤드가 디코더 스킵 텐서마다 잔차 하나와 중간 블록용 잔차 하나를 만들어 UNet의 기존 ControlNet 인터페이스로 더한다. 동시에 각 교차 어텐션 지점이 조건 특징의 3×3 창을 참조하며, 0으로 초기화된 채널별 게이트를 거친다. 두 경로 모두 초기에는 정확한 무연산이다. 둘을 끄면 네트워크가 원본 Stable Diffusion 1.5 [26]를 비트 단위로 재현하며, 모든 학습 전에 이를 검사한다.

학습. SD1.5 [26]는 냉동한다. BLIP [11] 캡션이 달린 FFHQ-512 [10] 65,100장에서 6,611,469개 파라미터를 배치 32, bf16, 12에폭, H200 한 장으로 학습한다. r 은 샘플마다 $[0, 1]$ 균등분포에서 뽑는다.

4 실험

보류한 3,500장에서 샘플러 50스텝, CFG 7.5, 시드 2026으로 평가한다. FID [4]는 clean-FID 프로토콜 [19]로, LPIPS [35]와 CLIP 점수 [25]를 함께 보고한다. 구조 순응도(SC)는 생성된 이미지에서 같은 차단 반경으로 조건을 다시 추출해 모델이 받은 조건과 상관을 낸다. 정답 이미지를 그대로 넣으면 모든 r 에서 정확히 1.000이 나오고, 무관한 얼굴은 $r=0$ 에서 0.122, 그 위에서는 ≈ -0.02 가 나온다.

4.1 다이얼

표 1이 동작 곡선이다. 구조 순응도는 $r=0.05$ 부터 단조 감소하고 표본 다양성은 단조 증가한다. 다이얼이 드러내야 할 균형이 그대로 나타난다. FID는 전

r	SC	다양성	LPIPS	CLIP	FID
0.00	0.6991	0.2994	0.3341	29.54	50.13
0.05	0.7469	0.3126	0.3495	29.41	51.58
0.10	0.6211	0.3414	0.3748	29.53	54.68
0.20	0.4019	0.3719	0.4003	29.47	53.45
0.30	0.2347	0.3794	0.4148	29.73	52.77
0.50	0.1259	0.4100	0.4418	29.78	53.97
0.70	0.1110	0.4334	0.4625	29.92	53.69
1.00	0.0010	0.5066	0.5329	30.30	57.40

Table 1: 동작 곡선. 테스트 3,500장 중 500장 샘플.

구간에서 50.13과 57.40 사이에 머무르므로, 구간이 끝까지 쓸 만하게 유지되고 잡음으로 무너지지 않는다.

그림 3은 시드와 캡션을 고정하고 r 만 바꾼 것이다. 그림 4는 곡선과, 그 아래에 두 다이얼을 같은 구조 순응도/FID 평면에 함께 놓은 것이다.

시드 2026, 2027, 2028에서 곡선은 안정적이다. $r=0.05$ 의 SC는 0.7479 ± 0.0015 , $r=0.3$ 은 0.2318 ± 0.0106 다.

4.2 세기는 같은 손잡이가 아니다

당연한 대안은 하나의 차단 반경으로 학습하고 추론 시 어댑터 기여를 스케일하는 것이다. 같은 체크포인트에서 $r=0.1$ 을 고정하고 두 주입 경로를 함께 스케일해 시험했다.

설정	SC	다양성	FID
세기 0.25	0.0408	0.7752	104.95
세기 0.50	0.2146	0.6061	76.46
세기 0.75	0.4893	0.4171	58.90
$r=0.3$ (우리)	0.2347	0.3794	52.77
$r=0.5$ (우리)	0.1259	0.4100	53.97

Table 2: 세기 다이얼과 주파수 다이얼. 같은 SC에서 읽으면 세기 0.50은 0.2146을 FID 76.46에 도달하고, $r=0.3$ 은 0.2347을 FID 52.77에 도달한다.

어댑터를 약하게 하면 이미지가 나빠지고, 조건의 대역폭을 좁히면 그렇지 않다. 주파수 파라미터화가 이 균형을 이동 가능하게 만든다.

4.3 VAE가 조건을 먹는다

IP-Adapter [32] 계열 설계처럼 조건을 냉동 SD VAE로 인코딩하면 대부분을 잃는다. 그림 5가 이를 보여준다. 조건을 인코딩-디코딩 왕복시킨 뒤 다시 재면 $r=0.1$ 에서 0.8562, $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700가 남는다. 그 잡재를 읽는 어댑터는 오토인코더가 이미 버린 정보를 복구할 수 없다. 조건을 256에서 만들어 업샘플하면 구조가 더 낮은 절대 주파수로 옮겨가 훨씬 많이 보존되는데 ($r=0.3$ 에서 0.7978), 이는 예전 설정과 비교할 때 알아둘 만한 데이터 파이프라인 인공물이다.

4.4 어디에 주입할 것인가

같은 인코더와 학습 일정에서 시작해 한 번에 한 필드씩 바꿨다(표 3). 스킵 연결 잔차가 지배적이다. 그림 6가




Figure 1: 주파수 쪽에서 본 다이얼. 열은 $r = 0, 0.05, 0.1, 0.2, 0.3, 0.5, 0.7, 1.0$ 이다. **1행:** 방사형 마스크, 검은 부분이 제거된다. **2행:** 마스크링 후 로그 크기 스펙트럼으로, 구멍이 바깥으로 커진다. **3행:** 모델이 실제로 받는 조건. **4행:** 같은 데이터를 $\pm 2\sigma$ 로 표시해 남아 있는 내용을 드러낸 것. $r \approx 0.2$ 위에서 조건은 평평한 회색으로 보이고 표준편차도 $r=0$ 의 0.196에서 $r=1$ 의 0.041로 떨어지지만, 4행에는 얼굴 윤곽이 남아 있고 모델은 $r=0.2$ 에서 SC 0.4019에 도달한다. 낮은 대비가 정보 없음을 뜻하지 않으며, 이미지별 정규화가 모델에 그것을 학습하도록 강제한다.

이를 분해한다. 제거하고 교차 어텐션만 남기면 $r=0$ 의 SC가 0.6991에서 0.2112로 떨어지고, 스킵 경로만 남기면 0.5370가 유지된다. 두 경로를 모두 끄면 SC 0.0368, FID 120.50로 무너지는데, 이것이 어댑터가 일을 하고 있다는 대조군이다.

용량은 훨씬 덜 기여한다. 투영을 128채널 스템으로 넓히면 $r=0.05$ 의 SC가 0.1485에서 0.2826로 오르고, 다시 256으로 두 배 늘려도 0.2986에 그친다. 7×7 어텐션 창은 3×3 보다 나쁘다 (0.0359).

변형	SC $r=0.05$	SC $r=0.1$	FID $r=0.1$
VAE 조건, 어텐션만	0.0234	0.0147	76.25
+ 0초기화 게이트	0.0303	0.0177	65.71
합성곱 조건 인코더	0.1485	0.0772	56.39
+ 128채널 스템	0.2826	0.1882	53.17
+ 256채널 스템	0.2986	0.2158	52.84
+ 7×7 창	0.0359	0.0218	58.51
+ 스킵 잔차	0.7469	0.6211	54.68

Table 3: 각 행은 위 행에서 한 필드만 바꾼 것이다.

4.5 차단 반경별 특화 모델과의 비교

고정 r 로 어댑터 네 개를 학습해 각자의 차단 반경에서 무작위- r 모델 하나와 비교했다. 결과는 엇갈린다. $r=0.1$ 에서는 특화 모델이 이기고 (0.7049 대 0.6211, $z = +17.5$), $r=0.7$ 에서도 근소하게 이긴다 ($z = +2.6$). $r=0.3$ 에서는 하나의 모델이 이기고 (0.2347 대 0.1214, $z = -19.0$), $r=0.5$ 는 무승부다 ($z = -0.7$).

따라서 모델 하나가 넷을 압도하지는 않는다. 대신 특화 모델이 줄 수 없는 것을 준다. $r=0.1$ 로 학습한 모델은 $r=0.3$ 을 본 적이 없으므로 그 곡선은 점 하나다.

4.6 베이스라인

같은 테스트 이미지와 캡션에서 사전학습 ControlNet [34]을 자기 조건으로 돌린 결과다. ControlNet-Canny는 Edge-F1 0.6854, LPIPS 0.5294, FID 71.92이고 학습 파라미터는 361,279,120개다. ControlNet-HED는 0.5733 / 0.6548 / 118.98다. $r=0.1$ 에서 우리 어댑터는 Edge-F1 0.7439, LPIPS 0.3748, FID 54.68를 6,611,469개 파라미터로 낸다. 조건이 다르므로 — Canny 엣지 대 주파수 대역 — 이는 동일 조건 비교가 아니라 동작점 비교다.

4.7 손으로 그린 스케치

그림 7이 전이 결과다. 학습에 쓰인 적 없는 실제 얼굴 그림 40장에서, 입력 그림에 대한 구조 순응도는 0.5484, CLIP 점수는 23.43이다. FID는 보고하지 않는다. 40장은 안정적인 추정에 부족하고, 평가기가 값을 내는 대신 거부한다.

5 한계

쓸 만한 구간은 대략 $r \in [0, 0.3]$ 이다. 그 위에서는 조건에 남은 에너지가 적어 — $r=0.5$ 에서 스펙트럼의 0.0014 — 구조 순응도를 해석하기 어려워진다. 거의 비어 있는 두 신호는 모델이 무엇을 하든 상관이 0에 가깝기 때문이다.

여기 있는 모든 것은 한 도메인(FFHQ 얼굴)과 한 백본(SD1.5)이다. 현재의 구조 제어 연구는 DiT 백본 [1, 20]으로 옮겨갔고, 거기서 LoRA [7] 계열 어댑터 [15, 30, 36]는 우리보다 훨씬 적은 파라미터로 제어를 보고한다. 우리 효율 수치는 ControlNet 대비로 읽어야 하며 그 연구선과 비교할 것이 아니다.




Figure 2: 조건 생성(위)과 두 주입 경로. 반경 r 의 원판을 스펙트럼에서 제거하고, 학습되는 합성곱 인코더가 그 결과를 전체 해상도로 읽는다. 굵은 선이 학습되는 부분이며 (6,611,469개 파라미터), 음영 블록은 냉동이고, $\oplus$ 는 0으로 초기화된 잔차가 skip 텐서에 더해지는 지점이다. 두 경로를 모두 끄면 네트워크가 원본 SD1.5를 정확히 재현한다. skip 경로가 구조 신호의 대부분을 나르며, 4.4절이 그 분배를 측정한다.

특화 모델 비교는 정직하지만 $r=0.1$ 에서 불리하고, 사용자 연구는 수행하지 않았다.

6 결론

학습 중 구조 조건의 대역폭을 무작위화하면 차단 반경이 추론 시 제어가 되고, 그 제어는 어댑터를 약하게 만드는 것으로 재현되지 않는다. 여기에 도달하려면 조건이 네트워크에 들어가는 위치를 고치고 조건을 냉동 오토인코더 밖에 두어야 했다. 두 발견은 다이얼을 무엇에 쓰는 다른 조건화 설계에도 옮겨간다.

References

- [1] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling rectified flow transformers for high-resolution image synthesis. arXiv:2403.03206, 2024. URL <https://arxiv.org/abs/2403.03206>.
- [2] Tiankai Hang, Shuyang Gu, Chen Li, Jianmin Bao, Dong Chen, Han Hu, Xin Geng, and Baining Guo. Efficient diffusion training via min-snr weighting strategy. arXiv:2303.09556, 2023. URL <https://arxiv.org/abs/2303.09556>.
- [3] Yinxi He, Kang Liao, Chunyu Lin, Tianyi Wei, and Yao Zhao. Structdiff: A structure-preserving and spatially controllable diffusion model for single-image generation. arXiv:2604.12575, 2026. URL <https://arxiv.org/abs/2604.12575>.
- [4] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. Gans trained by a two time-scale update rule converge to a local nash equilibrium. arXiv:1706.08500, 2017. URL <https://arxiv.org/abs/1706.08500>.
- [5] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. arXiv:2207.12598, 2022. URL <https://arxiv.org/abs/2207.12598>.
- [6] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. arXiv:2006.11239, 2020. URL <https://arxiv.org/abs/2006.11239>.
- [7] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. arXiv:2106.09685, 2021. URL <https://arxiv.org/abs/2106.09685>.
- [8] Chao Huang, Susan Liang, Yunlong Tang, Jing Bi, Li Ma, Yapeng Tian, and Chenliang Xu. Fresca: Scaling in frequency space enhances diffusion models. arXiv:2504.02154, 2025. URL <https://arxiv.org/abs/2504.02154>.
- [9] Sida Huang, Siqi Huang, Ping Luo, and Hongyuan Zhang. Laytrol: Preserving pretrained knowledge in layout control for multimodal diffusion transformers. arXiv:2511.07934, 2025. URL <https://arxiv.org/abs/2511.07934>.



Figure 3: 시드와 캡션을 고정하고 r 만 바꾼 결과. 왼쪽부터 참조 이미지, $r = 0, 0.05, 0.1, 0.3, 0.5, 0.7, 1.0$. 배경의 인파가 벌어지고 안경테가 참조에서 멀어지며 옷 색이 분리되는 반면 신원과 자세는 남는다. 참조 이미지는 모델에 주어지지 않는다.




Figure 4: 위: 차단 반경이 커질수록 구조 순응도는 내려가고 표본 다양성은 올라간다. 아래: 같은 실행들을 구조 순응도/FID 평면에 놓은 것. 조건의 대역폭을 좁히면 FID가 거의 일정한 채로 축을 이동하고, 어댑터를 약하게 하면 같은 구조 순응도를 이미지 품질로 지보한다. 두 패널 모두 평가 출력에서 직접 그렸다.

- [10] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. arXiv:1812.04948, 2018. URL <https://arxiv.org/abs/1812.04948>.
- [11] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. arXiv:2201.12086, 2022. URL <https://arxiv.org/abs/2201.12086>.
- [12] Ming Li, Taojiannan Yang, Huafeng Kuang, Jie Wu, Zhaoning Wang, Xuefeng Xiao, and Chen Chen. Controlnet++: Improving conditional controls with efficient consistency




Figure 5: 오토인코더에 넣은 조건과, 인코딩-디코딩 왕복 후 다시 추출한 조건 사이의 상관, 24장. $r \approx 0.5$ 위에서는 조건이 사실상 사라지므로 VAE 잠재를 읽는 어댑터는 이를 복구할 수 없다. 조건을 256에서 만들어 확대하면 구조가 더 낮은 절대 주파수에 놓여 훨씬 많이 보존되며, 예전 파이프라인과 비교할 때 소스 해상도를 명시해야 하는 이유다.

feedback. arXiv:2404.07987, 2024. URL <https://arxiv.org/abs/2404.07987>.

- [13] Yuheng Li, Haotian Liu, Qingyang Wu, Fangzhou Mu, Jianwei Yang, Jianfeng Gao, Chunyuan Li, and Yong Jae Lee. Gligen: Open-set grounded text-to-image generation. arXiv:2301.07093, 2023. URL <https://arxiv.org/abs/2301.07093>.
- [14] Xin Lin, Haodong Li, Zhifei Zhang, Yutong Yang, Haitian Zheng, Juanxi Tian, Zhe Lin, and Truong Nguyen. Pixelcontrol: Fine-grained condition fidelity in text-to-image diffusion. arXiv:2608.15705, 2026. URL <https://arxiv.org/abs/2608.15705>.
- [15] Shanyuan Liu, Jian Zhu, Junda Lu, Yue Gong, Li-uzhuozheng Li, Bo Cheng, Yuhang Ma, Liebuchu Wu, Xiaoyu Wu, Dawei Leng, and Yuhui Yin. Nanocontrol: A lightweight framework for precise and efficient control in diffusion transformer. arXiv:2508.10424, 2025. URL <https://arxiv.org/abs/2508.10424>.




Figure 6: 두 주입 경로를 모두 켜는 경우, 각각 단독, 그리고 둘 다 끈 경우. skip 잔차가 구조 신호의 대부분을 나르고, 교차 어텐션 단독으로는 거의 회복하지 못하며, 둘 다 끄면 냉동 백본으로 떨어진다(FID 120.50, 양쪽 켜었을 때는 50.13). 두 경로는 거의 가산적이다.



Figure 7: 손으로 그린 얼굴 스케치(홀수 열)와 모델이 만든 결과(짝수 열), 제로샷. 그림에는 차단 반경이 없으므로 모델이 그림 자체에서 구조 밀도를 읽어야 하며, 조건의 이미지별 최소-최대 정규화가 이를 가능하게 한다.

- [16] Zehong Ma, Longhui Wei, Shuai Wang, Shiliang Zhang, and Qi Tian. Deco: Frequency-decoupled pixel diffusion for end-to-end image generation. arXiv:2511.19365, 2025. URL <https://arxiv.org/abs/2511.19365>.
- [17] Chong Mou, Xintao Wang, Liangbin Xie, Yanze Wu, Jian Zhang, Zhongang Qi, Ying Shan, and Xiao-hu Qie. T2i-adapter: Learning adapters to dig out more controllable ability for text-to-image diffusion models. arXiv:2302.08453, 2023. URL <https://arxiv.org/abs/2302.08453>.
- [18] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever, and Mark Chen. Glide: Towards photorealistic image generation and editing with text-guided diffusion models. arXiv:2112.10741, 2021. URL <https://arxiv.org/abs/2112.10741>.
- [19] Gaurav Parmar, Richard Zhang, and Jun-Yan Zhu. On aliased resizing and surprising subtleties in gan evaluation. arXiv:2104.11222, 2021. URL <https://arxiv.org/abs/2104.11222>.
- [20] William Peebles and Saining Xie. Scalable diffusion models with transformers. arXiv:2212.09748, 2022. URL <https://arxiv.org/abs/2212.09748>.
- [21] Bohao Peng, Jian Wang, Yuechen Zhang, Wenbo Li, Ming-Chang Yang, and Jiaya Jia. Controlnext: Powerful and efficient control for image and video generation. arXiv:2408.06070, 2024. URL <https://arxiv.org/abs/2408.06070>.
- [22] Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. Sdxl: Improving latent diffusion models for high-resolution image synthesis. arXiv:2307.01952, 2023. URL <https://arxiv.org/abs/2307.01952>.
- [23] Arisha Prasain. Beyond edge maps: Wavelet-domain conditioning for multi-adapter map-to-satellite diffusion. arXiv:2608.00083, 2026. URL <https://arxiv.org/abs/2608.00083>.
- [24] Can Qin, Shu Zhang, Ning Yu, Yihao Feng, Xinyi Yang, Yingbo Zhou, Huan Wang, Juan Carlos Niebles, Caiming Xiong, Silvio Savarese, Stefano Ermon, Yun Fu, and Ran Xu. Unicontrol: A unified diffusion model for controllable visual generation in the wild. arXiv:2305.11147, 2023. URL <https://arxiv.org/abs/2305.11147>.
- [25] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. arXiv:2103.00020, 2021. URL <https://arxiv.org/abs/2103.00020>.
- [26] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. arXiv:2112.10752, 2021. URL <https://arxiv.org/abs/2112.10752>.
- [27] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S. Sara Mahdavi, Rapha Gontijo Lopes, Tim Salimans, Jonathan Ho, David J Fleet, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. arXiv:2205.11487, 2022. URL <https://arxiv.org/abs/2205.11487>.
- [28] Chenyang Si, Ziqi Huang, Yuming Jiang, and Ziwei Liu. Freeu: Free lunch in diffusion u-net. arXiv:2309.11497, 2023. URL <https://arxiv.org/abs/2309.11497>.
- [29] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. arXiv:2010.02502, 2020. URL <https://arxiv.org/abs/2010.02502>.
- [30] Zhenxiong Tan, Songhua Liu, Xingyi Yang, Qiaochu Xue, and Xinchao Wang. Ominicontrol: Minimal and universal control for diffusion transformer. arXiv:2411.15098, 2024. URL <https://arxiv.org/abs/2411.15098>.
- [31] Gabriel Tjio, Jie Zhang, Xulei Yang, Yun Xing, Nhat Chung, Xiaofeng Cao, Ivor W. Tsang, Chee Keong Kwok, and Qing Guo. Focus: Frequency-optimized conditioning of diffusion models for mitigating catastrophic forgetting during test-time adaptation. arXiv:2508.14437, 2025. URL <https://arxiv.org/abs/2508.14437>.

- [32] Hu Ye, Jun Zhang, Sibor Liu, Xiao Han, and Wei Yang. Ip-adapter: Text compatible image prompt adapter for text-to-image diffusion models. arXiv:2308.06721, 2023. URL <https://arxiv.org/abs/2308.06721>.
- [33] Bo Yin, Xiaobin Hu, Xingyu Zhou, Yu He, Peng-Tao Jiang, Yue Liao, Junwei Zhu, Jiangning Zhang, Ying Tai, and Shuicheng Yan. Fera: Frequency-energy constrained routing for effective diffusion adaptation fine-tuning. arXiv:2511.17979, 2025. URL <https://arxiv.org/abs/2511.17979>.
- [34] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. arXiv:2302.05543, 2023. URL <https://arxiv.org/abs/2302.05543>.
- [35] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. arXiv:1801.03924, 2018. URL <https://arxiv.org/abs/1801.03924>.
- [36] Yuxuan Zhang, Yirui Yuan, Yiren Song, Haofan Wang, and Jiaming Liu. Easycontrol: Adding efficient and flexible control for diffusion transformer. arXiv:2503.07027, 2025. URL <https://arxiv.org/abs/2503.07027>.
- [37] Shihao Zhao, Dongdong Chen, Yen-Chun Chen, Jianmin Bao, Shaozhe Hao, Lu Yuan, and Kwan-Yee K. Wong. Uni-controlnet: All-in-one control to text-to-image diffusion models. arXiv:2305.16322, 2023. URL <https://arxiv.org/abs/2305.16322>.
- [38] Chao Zhou, Tianyi Wei, Yiling Chen, Wenbo Zhou, and Nenghai Yu. Rethinking multi-condition dits: Eliminating redundant attention via position-alignment and keyword-scoping. arXiv:2602.06850, 2026. URL <https://arxiv.org/abs/2602.06850>.