

구조 조건부 확산 모델을 위한 주파수 다이얼

익명 제출

초록

구조 조건부 확산 어댑터는 하나의 동작점에서 학습된다. 출력이 조건을 얼마나 가깝게 따르는지 학습 시점에 고정되고, 나중에 느슨하게 하려면 다른 체크포인트를 쓰거나 어댑터 세기를 낮춰야 한다. 우리는 그 선택을 조건 쪽으로 옮긴다. Stable Diffusion 1.5 위의 어댑터 하나를 회색조 이미지에 방사형 고주파 통과 필터를 걸어 학습하되, 차단 반경 r 을 샘플마다 뽑는다. 추론 시 r 은 다이얼이 되며, 이미지 편집 도구가 사용자에게 주파수 대역을 고르게 하는 것과 같은 방식이다. FFHQ-512에서 r 을 0.05에서 0.3으로 올리면 구조 순응도(학습 seed 세 개의 평균)가 0.7479에서 0.2318로 낮아지고 FID는 51.58와 54.68 사이에 머문다. 우리 샘플에서는 얼굴 배치가 유지되는 동안 배경·의복·색이 참조에서 멀어진다. 대신 어댑터 세기를 낮추면 느슨해진 구조의 대가를 FID로 치른다. 세기 0.50에서 구조는 같은 고정 계측기 기준 $r=0.3$ 보다 느슨하고 FID는 52.77 대신 76.46이다. $r=0.1$ 에서는 그 차단 반경만으로 학습한 어댑터가 구조를 더 가깝게 따른다. UNet의 skip 텐서로 주입하는 경로가 구조의 대부분을 나르며, 화가는 손그림에 같은 필터를 걸 수 있다. 그때도 출력과 그림의 상관은 r 이 커질수록 떨어진다.

1 서론

이미지 편집은 오래전부터 사용자에게 돌릴 수 있는 스케일이나 주파수 대역을 주었고 [7, 31], 스케치 기반 얼굴 합성은 그림을 틀이 아니라 연성 제약으로 다뤘으며 [2], 어떤 시스템은 스케치를 얼마나 믿을지 명시적으로 조절하게 했다 [51]. ControlNet [55]과 그 후속 연구들 [22, 28, 38, 59]은 그 제어를 학습 안으로 옮겼다. Canny 엣지로 학습한 어댑터는 Canny 엣지를 따르고, 깊이로 학습한 어댑터는 깊이를 따른다. 그러니 구조를 더 느슨하게 따르게 하려면 다른 체크포인트를 고르거나 추론 시 어댑터를 약하게 해야 한다.

우리는 모델이 얼마나 귀 기울이는지가 아니라 조건 자체를 바꾼다. 다중 스케일 편집은 출력 이미지의 대역을 제거하거나 증폭하지만 [7, 31], 여기서는 대역을 조건에서 제거하고 무엇으로 채울지는 생성 사전분포가 정한다. 조건은 정규화된 차단 반경 r 의 방사형 고주파 통과 필터를 거친 이미지다. $r=0$ 에서 모델은 회색조 이미지를 받고 과제는 색복원이 된다. r 이 커질수록 필터가 스펙트럼을 더 많이 제거해 $r=1$ 에서는 거의 남지 않는다. FFHQ 테스트 이미지 500장에서 재면 차단 반경 0.05만으로도 상수항을 제외한 스펙트럼 에너지의 88.6%가 사라진다. 학습은 r 을 샘플마다 뽑으므로 가중치 하나가 전 구간을 보고, r 은 추론 시 파라미터가 된다. seed를 고정한 채 r 을 올리면 얼굴 배치는 그대로 두고 배경 디테일이 얹아지며 의복과 색이 참조에서 멀어진다(그림 3). 어댑터 세기를 낮추는 것은 다른 제어다. 세기가

낮아지면 자세와 구도가 바뀌고 FID가 오른다(4.3절). 기여는 다음과 같다.

- 조건 위의 주파수 다이얼. 학습 중 고주파 차단 반경을 무작위로 뽑으면 어댑터 하나가 $r \in [0.05, 0.3]$ 에서 구조 순응도를 추론 시에 조절할 수 있게 되고 FID는 한 대역에 머문다(4.2절). $r=0.1$ 에서는 차단 반경별 특화 모델에 뒤지고 $r=0.3$ 에서는 앞선다(4.4절).
- 다이얼은 어댑터 세기가 아니다. 하나의 고정 계측기로 보면, 차단 반경이 내는 구조 순응도 근처의 세기 설정들은 더 높은 FID에 놓고 자세와 구도를 바꾼다 (4.3, 4.1절).
- 조건이 UNet의 어디로 들어가야 하는가(5절). SD1.5에서 skip 텐서 경로가 교차 어텐션만으로는 나르지 못하는 구조의 대부분을 나르며 (5.2, 5.3절), 어텐션 단독 주입에서는 합성곱 인코더가 동결 VAE보다 조건을 잘 읽는다(표 4).

2 관련 연구

조건부 제어. 텍스트-이미지 확산 모델 [16, 29, 40, 41, 43]은, Po 등 [35]이 비주얼 컴퓨팅 관점에서 정리했듯, ControlNet [55]으로 공간 제어가 가능해졌다. 작은 합성곱 네트워크로 조건 이미지를 읽고, 인코더를 복제하며, 0 합성곱으로 잔차를 주입한다. T2I-Adapter [28]는 작은 특징 추출기로 같은 일을 하고, IP-Adapter [52]는 이미지 프롬프트를 위한 분리형 교차 어텐션을 더하며, GLIGEN [23]은 박스로 생성을 접지한다. Uni-ControlNet [59]과 UniControl [38]은 여러 조건 유형을 한 모델에 담고, ControlNet++ [22]는 생성된 이미지에서 일관성 루프를 단는다. 같은 UNet에서 제어 분기를 줄이는 흐름도 있다. ControlNet-XS [54]는 훨씬 작은 제어 네트워크를 인코더·디코더와 양방향으로 연결하고, CtrLoRA [50]는 공유된 기반 ControlNet을 조건마다 LoRA로 적응시키며, Simple-ControlNet [8]은 UNet 최상단의 단일 스케일 투영과 self-attention의 LoRA만으로 300만 미만의 파라미터에서 조건을 넣고 추론 시 그 투영의 스케일을 조절하게 한다. 이들은 모두 학습 때 조건 유형을 고정하고, 그와 함께 출력이 얼마나 따를지도 고정한다. Simple-ControlNet의 추론 시 스케일은 어댑터를 약하게 해서 그 동작점을 옮긴다. 우리의 차단 반경은 가중치 하나에서 조건을 통해 동작점을 옮기며, 우리 어댑터에서 두 제어는 FID에서 갈린다(4.3절).

트랜스포머 백본에서의 효율적 제어. 백본이 UNet에서 확산 트랜스포머 [6, 33]로 옮겨가면서 제어도 복제 인코더에서 경량 모듈로 이동했다. ControlNeXt [34]는 병렬 분기를 없애고, OminiControl [44]은 백본 자체를 조건 처리기로 재사용하며, EasyControl [58]과 NanoControl [25]은 LoRA [17] 계열 모듈로

훨씬 적은 파라미터에서 조건을 주입한다. 최근 연구는 조건이 이 모델들에 들어가는 방식도 다시 본다. Laytrol [19]은 레이아웃 제어에서 사전학습 지식을 보존하려고 백본의 파라미터를 물려받고, PixelControl [24]은 VAE의 공간 압축이 고주파·저면적 조건 신호를 약화시킬 수 있다고 지적하며, Zhou et al. [60]은 다중 조건 DiT에서 결합 후 어텐션 방식을 위치 정렬 어텐션과 키워드 범위 어텐션으로 바꾼다. UNet에서는 skip 텐서가 진입점으로 존재하므로 이 질문이 구체적인 형태를 띤다. 우리 비교(5.2절)에서는 skip 잔차가 교차 어텐션보다 더 많은 구조를 나른다.

편집 축으로서의 주파수 대역. 대역 분해는 그래픽스의 표준적인 편집 축이다. 세부 조작은 엷지 보존 분해나 라플라시안 분해의 대역을 다시 스케일하고 [7, 31], 하이브리드 이미지는 한 그림의 저주파와 다른 그림의 고주파를 합쳐 보는 거리에 따라 해석이 바뀌게 한다 [30]. 확산 연구에서 주파수 분해는 대개 조건이 아니라 모델 자신의 신호에 대한 개입으로 나타난다. FreeU [42]는 skip과 백본 특징을 학습 없이 스펙트럼 상에서 재조정하고, FreSca [18]는 공간 또는 에너지 기반 차단으로 노이즈 예측의 주파수 대역을 스케일하며, DeCo [26]는 픽셀 공간 확산에서 주파수를 분리하고, FeRA [53]는 주파수 에너지로 적응을 라우팅한다. FOCUS [45]는 테스트 시 적응을 위해 학습된 주파수 사전으로 역과정을 조건화한다. 제어 대상의 선택에서 가장 가까운 것은 주파수 대역을 이미지-이미지 유도의 제어로 쓰는 연구다. FCDiffusion [10]은 소스 특징의 DCT 대역을 뽑아 주파수 제어 분기를 바꿔 가며 쓰고, FBSDiff [9]는 학습 없이 대체 대역의 대역폭으로 참조의 유도 강도를 정하며, ILVR [5]은 추가 학습 없이 선택한 다운샘플링 배율에서 참조로 사전학습 DDPM을 조건화한다. 필터 유도 확산 [11]은 추론 시 디노이즈 추정값에 공간 필터를 걸고 그 스케일과 유도 강도를 학습 없이 별개의 제어로 노출한다. 우리의 대역은 그와 달리 어댑터가 읽도록 학습되는 대상의 일부다. Prasain [37]는 지도-위성 합성에서 엷지 맵 대신 웨이블릿 대역으로 조건화한다. 그러나 어느 연구도 학습 중 조건의 대역폭을 무작위화해 그 대역이 추론 시 제어가 되게 하지는 않는다. 조건 파라미터를 학습 중 무작위화하고 추론 시 노출하는 것 자체는 새롭지 않다. SDXL [36]은 데이터 로딩 중 크롭 좌표를 뽑아 사용자 제어로 드러내고, Imagen [41]은 저해상도 조건의 증강 수준을 학습 때 무작위로 뽑고 추론 때 훑는데, 그 목적은 사용자 제어가 아니라 최고 표본 품질을 찾는 것이다. 우리의 차이는 파라미터의 선택과, 그것이 어댑터 세기와 측정상 분리된다는 점이다. 대역폭과 어댑터 세기는 서로 다른 제어다(4.3절).

연성 제약으로서의 그림. 스케치 기반 얼굴 합성은 거친 그림을 연성 제약으로 다뤘고 [2], 우리 목표에 가장 가깝게는 정제 수준으로 사용자가 그림을 얼마나 믿을지 정하게 했다 [51]. 확산 기반 획·스케치 합성도 입력에 대한 충실도 수준을 사용자가 정하게 한다 [4]. 사전학습 확산 모델에서는 전용 인코더 대신 작은 잠재 유도 예측기로 추론 시 스케치 유도를 걸 수 있고 [46], 디노이징 전에 더하는 노이즈가 학습 없이 입력 충실도와 사실성의 균형을 잡는다 [27].

XDoG [48]는 필터 한 족의 파라미터를 바꿔 사진을 연필 음영에서 해칭, 목판화로 옮긴다. 우리의 차단 반경도 같은 종류의 필터 파라미터이며, 조건 위에 설정되고 나머지는 생성 사전분포가 채우도록 남긴다. 우리 제어는 바꾸는 대상이 다르다. 주파수 차단 반경이 정하는 조건의 정보량을, 세기와 따로 반응을 측정하는 어댑터 하나에서 바꾼다. 조건이 고정된 추출기가 아니라 연속체이므로 어댑터 하나가 그것을 다이얼로 노출할 수 있다. StructDiff [13]는 구조를 보존하는 공간 제어형 단일 이미지 생성을 목표로 하며, 소스 이미지 한 장의 내부 통계 안에서 샘플을 다양화하면서 그 배치를 유지한다. 우리는 그 대신 외부 조건을 쥐고, 차단 반경이 그중 얼마를 출력에 재현해야 하는지를 정한다.

3 방법

조건. 이미지 x 를 회색조로 바꾸고 2차원 FFT를 취한 뒤 반지름 $r \cdot \min(H, W)/2$ 원판 안의 모든 주파수를 0으로 만들고 역변환한 다음 $[0, 1]$ 로 최소-최대 정규화한다. 정규화는 의도적이다. 필터 응답의 절대 크기를 없애 모델이 공간 통계만으로 구조 밀도를 추론하게 만든다. r 을 갖지 않는 손그림을 추론 시 쓸 수 있는 이유가 여기에 있다고 가정한다. 필터를 고주파 통과로 둔 것은 형태만 남기고 나머지를 사전 분포에 넘기려는 것이다. 엷지와 질감은 고대역에, 톤과 색은 저대역에 있으며 이는 두 스케일 톤·디테일 편집 [1, 7]이 다루는 구분이다. 저주파 통과나 대역 통과 조건이라면 우리가 모델에게 만들어내라고 맡기려는 부분을 오히려 넘겨주게 된다. 우리가 더하는 것은 그 경계가 고정된 추출기가 아니라 파라미터라는 점이다. 마스크를 부드러운 감쇠가 아니라 이상적 원판으로 둔 것은 r 이 어떤 주파수가 사라졌는지를 정확히 지칭하게 하기 위해서이며, 대가는 그림 1의 조건에 보이는 링잉이다. 모델은 그 링잉을 포함해 학습되며 우리는 이를 따로 측정하지 않았다. 그림 1는 차단 반경별 마스크, 스펙트럼, 조건을 보여준다.

조건 인코더. 합성곱 인코더가 512^2 조건 이미지를 직접 읽어 잠재 격자로 $8 \times$ 줄인다. SiLU 활성화를 쓰는 3×3 합성곱 일곱 개로 이루어지며, 그중 셋은 스트라이드 2이고 뒤에 그룹 정규화가 붙는다. 채널은 32에서 128까지 넓어진 뒤 마지막에 4로 투영된다. 각 어텐션 지점은 인코더 출력을 1×1 투영으로 읽는다. 어블레이션에서는 이 투영 앞에 넣는 64, 128, 256채널의 선택적 3×3 합성곱을 스템이라 부르며, 주 모델에는 스템이 없다. 조건은 동결 VAE가 아니라 이 합성곱 인코더로 읽는다. 왕복 측정은 5.1절에 있다.

주입. 인코더 특징은 UNet에 두 곳으로 들어간다(그림 2). 0으로 초기화된 1×1 헤드가 디코더 skip 텐서마다 잔차 하나와 중간 블록용 잔차 하나를 만들어 UNet의 기존 ControlNet 인터페이스로 더한다. 동시에 각 교차 어텐션 지점이 조건 특징의 3×3 창을 참조하며, 0으로 초기화된 채널별 게이트를 거친다. 1×1 에서는 softmax가 한 위치에 대해서만 계산되어 이 지점이 게이트 달린 값 투영으로 줄어드는데, 구조 순응도는 시드 퍼짐을 넘어 낮아지지 않는다(5.2절). 두 경로 모두 처음에는 정확한 무연산이다. 둘을 끄면




그림 1: 주과수 쪽에서 본 다이얼. 열은 $r = 0, 0.05, 0.1, 0.2, 0.3, 0.5, 0.7, 1.0$ 이다. **1행:** 방사형 마스크, 검은 부분이 제거된다. **2행:** 마스크링 후 로그 크기 스펙트럼으로, 구멍이 바깥으로 커진다. **3행:** 모델이 실제로 받는 조건. **4행:** 같은 데이터를 $\pm 2\sigma$ 로 표시해 남아 있는 내용을 드러낸 것. $r \approx 0.2$ 위에서 조건은 평평한 회색으로 보이고 테스트 이미지 500장 평균 표준편차도 $r=0$ 의 0.238에서 $r=1$ 의 0.034로 떨어지지만, 4행에는 얼굴 윤곽이 남아 있고 모델은 $r=0.2$ 에서 SC 0.4019에 도달한다. 이미지별 정규화 때문에 모델이 구조를 읽을 수 있는 것은 이 낮은 대비의 잔여뿐이다.

네트워크가 원본 Stable Diffusion 1.5 [40]를 비트 단위로 재현하며, 모든 학습 전에 이를 검사한다.

학습. SD1.5 [40]는 동결한다. BLIP [21] 캡션이 달린 FFHQ-512 [20](이미지는 Flickr 작성자의 크리에이티브 커먼즈 또는 퍼블릭 도메인 라이선스, 데이터셋은 CC BY-NC-SA 4.0)에서 6,611,469개 파라미터를 학습한다. 70,000장을 시드 2026으로 섞어 학습 65,100 / 검증 1,400 / 테스트 3,500로 나눈다(테스트 5%, 검증 2%). AdamW, 학습률 10^{-4} , $\beta = (0.9, 0.999)$, 500스텝 워밍업의 코사인 스케줄, 기울기 클리핑 1.0, 배치 32, bf16, H200 한 장에서 12에폭. 손실은 ϵ 예측에 Min-SNR 가중 [12] $\gamma = 5$ 를 적용한다. 텍스트 조건은 분류자 없는 유도 [15]를 위해 확률 0.1로, 구조 조건은 독립적으로 확률 0.05로 드롭한다. 조건을 회색조로 둔 것은 필터가 한 채널만 읽어 차단 반경의 의미가 모든 이미지에서 같아지도록 하기 위해서이며, 색은 사전분포에 남긴다. 표 5은 그 선택의 대조군으로 컬러 조건 행을, 구조 조건 드롭아웃 0.05의 대조군으로 드롭아웃 없는 행을 둔다. 학습은 12에폭에서 멈추는데, 그 지점에서 검증 곡선이 평평해진다. AdamW의 가중치 감쇠는 PyTorch 기본값 0.01이다. 어댑터의 EMA(감쇠 0.9999)를 10스텝 간격으로 유지하되 평가에는 원래 가중치를 쓴다. r 은 샘플마다 $[0, 1]$ 균등분포에서 뽑으므로 어댑터 하나가 전 구간을 본다. 결과를 $r \in [0.05, 0.3]$ 에서 보고하는 것은 그 구간이 제어가 쓸 만한 곳이기 때문이다. 왼쪽 끝에서는 sweep이 단조가 아니고 오른쪽 끝에서는 seed 간에 구분되지 않는다 (4.2절). 더 좁은 학습 구간은 시도하지 않았다. 나머지 설정은 부록 B에 있다.

4 실험

4.1 지표

보류한 3,500장 중 500장에서 DDIM 샘플러 50스텝, CFG 7.5, 시드 2026으로 평가한다.

구조 순응도. SC는 생성 이미지를 회색조로 바꾸고, 모델에 준 것과 같은 차단 반경으로 같은 고주파 필터를 적용한 뒤, 주어진 조건과의 Pearson 상관을 편 픽셀 벡터에 대해 이미지별로 계산해 평균한다. 두 신호 모두 이미지별 최소-최대 정규화된 필터 출력이므로 상관은 스케일에 무관하다. 두 앵커가 범위를 묶는다. 정답 이미지를 그대로 넣으면 모든 r 에서 정확히 1.000이고, 생성물을 다른 테스트 이미지의 조건과 비교하면 $r=0$ 에서 0.0847, $r=0.1$ 에서 0.0082다. 계측기가 r 과 함께 움직이므로 행 간 차이에는 모델 거동과 계측기 변화가 섞인다. 그래서 차단 반경과 무관한 지표를 함께 싣고, 아래에서 고정 계측기로도 읽는다.

Edge-F1. 8비트 회색조 이미지에서 Canny 엣지(임계 100, 200)를 생성물과 참조 양쪽에서 추출하고, 각 맵을 5×5 로 팽창시켜 교차하는 방식으로 2픽셀 허용 오차를 두어 대응시킨다. F1을 이미지별로 계산해 평균한다. r 에 의존하지 않으며 그래서 표 1에 실는다. $r=0.05$ 에서 0.7796, $r=1$ 에서 0.4724로 떨어지므로, 차단 반경과 무관한 계측기로 재도 다이얼이 살아 있다.

다양성. 하나의 조건에서 시드를 바꿔 생성한 $K=4$ 개 표본에 대한 평균 쌍별 LPIPS(AlexNet)다. 높을수록 조건이 덜 구속한다. 아래에서 정의하는 LPIPS 열과




그림 2: (a) 반경 r 의 원판을 스펙트럼에서 제거하고, 학습되는 합성곱 인코더가 그 결과를 전체 해상도로 읽는다. VAE는 거치지 않는다. 그 특징은 동결 UNet에 두 번 들어간다. 디코더로 가는 각 skip 텐서에 0으로 초기화된 잔차로($\oplus$; 그림에는 해상도 세 단계와 mid block이 그려져 있고, 네트워크에는 skip 헤드 12개와 mid 헤드 하나가 있다), 그리고 교차 어텐션 16곳의 StandAlone 어텐션으로. 선 굵기는 측정된 분배를 따른다. $r=0$ 에서 skip 경로만 켜면 SC가 0.5370, 어텐션만 켜면 0.2112다(5.2절). **(b)** StandAlone 한 지점. 쿼리는 UNet 자신의 latent에서 동결 W_Q 를 거쳐 오고, 키와 값은 조건에서 학습된 1×1 투영을 거쳐 온다. unfold로 각 위치가 전체 맵이 아니라 자기 3×3 이웃만 참조한다. 1×1 창도 적어도 그만큼 잘 작동한다(5.2절). 결과는 동결 출력 투영과 0초기화 채널별 게이트를 지나, latent에 더해져 아래의 텍스트 쿼리가 구조를 보게 하고, 층이 반환하는 값에도 더해진다.

독립이 아니다. 전 구간에서 LPIPS - 다양성이 0.0320 ± 0.0038 로, 다양성이 0.21만큼 변하는 동안 거의 상수다. 따라서 다양성은 LPIPS와 사실상 같은 정보를 담으며 보조 지표로 읽는다.

FID, LPIPS, CLIP. clean-FID [14, 32](clean 모드, 512픽셀)를 생성 500장과 같은 참조 500장 사이에서 잰다. LPIPS 열은 각 생성물과 자기 참조 사이의 AlexNet LPIPS [56]를 이미지 평균한 값이다. CLIP 점수는 ViT-B/32 [39]로 이미지와 자기 캡션을 임베딩한 코사인 유사도의 100배다.

고정 계측기. 구조 순응도는 모델이 받은 것과 같은 차단 반경에서 조건을 다시 추출하므로, 측정 계측기가 측정 대상과 함께 움직인다. 그래서 저장된 생성물을 차단 반경 $r_m=0.1$ 로 고정해 다시 채점한다. 저장된 8비트 이미지를 읽으므로 $r=0.1$ 에서 0.6210가 나오며, 양자화 이전에 계산한 표 1의 값은 0.6211다.

코드와 데이터. 코드, 설정 파일, 실행별 결과 파일, 주 모델의 체크포인트는 익명 저장소 https://anonymous.4open.science/w/Frequency_Adaptation-3125/에 있으며, 논문의 모든 수치는 그 결과 파일에서 스크립트 하나로 생성된다.

4.2 다이얼

표 1이 동작 곡선이다. $r \in [0.05, 0.3]$ 에서 구조 순응도는 매 단계 감소하는 동안 FID는 51.58와 54.68 사이에 머물고, 표본 다양성은 함께 오른다. $r=0$ 에서 $r=0.05$ 로 갈 때 구조 순응도는 0.0479만큼 상승하며($z = 6.24$, 500장에 대한 비대응 표준오차) 스위프는 왼쪽 끝에서 단조가 아니다. Edge-F1도 같은 방향으로 움직이지만($0.7776 \rightarrow 0.7796$) 그 변화에는

불확실도가 없어서, 모델 거동인지 SC 계측기의 인공물인지를 가리지 못한다. 우리는 이 상승을 $r=0$ 의 조건, 곧 회색조 이미지 전체가 저주파 성분을 너무 많이 담아 어댑터가 재현해야 할 옛지와 경합하기 때문으로 읽는다. 작은 원판을 도려내면 형태를 따라가기가 오히려 쉬워진다. 이는 측정한 것이 아니다. 오른쪽 끝에서는 $r=0.5$ 와 $r=0.7$ 이 시드 간에 구별되지 않는다(대응 $t = 0.732$, $df = 2$, 임계 4.303).

그림 3은 시드와 캡션을 고정하고 r 만 바꾼 것이다. 캡션이 참조에서 유도되므로 구조의 일부를 캡션이 나르고 있을 수 있다. 그래서 모든 이미지에 일반 캡션 하나("a photo of a person")를 주고 스위프를 반복했다. 구조 순응도는 가깝게 유지된다($r=0, 0.1, 0.3$ 에서 0.7039, 0.6179, 0.2196로, 캡션이 있을 때 0.6991, 0.6211, 0.2347). 반면 FID는 55.56–65.84로 오르는데, 캡션이 이미지를 설명하지 않게 되었으니 당연하다. 구조는 조건에서 온다. 그림 4는 곡선과, 그 아래에 차단 반경과 두 스케일 어댑터를 구조 순응도/FID 평면에 함께 놓은 것이다.

시드 2026, 2027, 2028에서 곡선은 안정적이다. $r=0.05$ 의 SC는 0.7479 ± 0.0015 , $r=0.3$ 은 0.2318 ± 0.0106 다.

4.1절의 고정 계측기로 다시 채점해도 곡선은 내려간다. $r=0.05$ 에서 0.6524, $r=0.1$ 에서 0.6210, $r=0.3$ 에서 0.2599다. 계측기를 고정하면 당연히 범위가 압축되지만 하락은 남는다.

4.3 대안 손잡이로서의 어댑터 세기

당연한 대안은 하나의 차단 반경으로 학습하고 추론 시 어댑터 기여를 줄이는 것으로, 경량 제어 모듈이 제공하는 손잡이이기도 하다 [8]. 고정 $r=0.1$ 로 학습한 어댑터(4.4절)에서 두 주입 경로를 함께 스케일해 이를 수행했고, 확인용으로 무작위- r 어댑터도 같은 차단 반경에서 스케일했다(표 2; 표 11은 더 촘촘한 스위프).




그림 3: 주 모델(학습 시드 2026)을 샘플링 시드 2026과 각 참조의 BLIP 캡션으로 돌린 것이며, 한 행 안에서는 r 만 바뀐다. 행은 테스트 이미지의 처음 세 장을 생성 순서대로 실은 것이고, 타일은 표 1에서 채점된 바로 그 저장된 생성물이다. 참조 이미지는 모델에 주어지지 않는다. r 이 커질수록 배경의 세부가 열어지고 옷과 색이 참조에서 멀어지지만 얼굴 배치는 유지되며, $r=1$ 에서는 첫 행에 색 인공물이 나타난다. 모든 출력은 이 논문이 다루는 모델이 생성한 것이다.

r	SC $\pm$ SEM	시드 sd	Edge-F1	다양성	FID
0.00	0.6991 $\pm$ 0.0070	0.0105	0.7776	0.2994	50.13
0.05	0.7469 $\pm$ 0.0030	0.0015	0.7796	0.3126	51.58
0.10	0.6211 $\pm$ 0.0035	0.0059	0.7439	0.3414	54.68
0.20	0.4019 $\pm$ 0.0037	0.0098	0.7113	0.3719	53.45
0.30	0.2347 $\pm$ 0.0041	0.0106	0.6878	0.3794	52.77
$r > 0.3$					
0.50	0.1259 $\pm$ 0.0047	0.0093	0.6225	0.4100	53.97
0.70	0.1110 $\pm$ 0.0047	0.0186	0.5788	0.4334	53.69
1.00	0.0010 $\pm$ 0.0006	0.0002	0.4724	0.5066	57.40

표 1: 동작 곡선. 테스트 3,500장 중 500장. 시드 sd를 뺀 모든 열은 학습 시드 2026에서 나온 값이고, 시드 sd는 학습 시드 2026–2028에 대한 표준편차이며, SEM은 그 500장에 대한 값이다. Edge-F1은 같은 실행을 차단 반경과 무관하게 읽은 것이며, SC가 모델에 준 것과 같은 차단 반경으로 재추출하기 때문에 함께 실행한다(4.1절). FID는 칸마다 추정값이 하나뿐이고 분산이 없으므로 행 간의 작은 차이를 효과로 읽지 않는다.

두 스케일 곡선 모두 줄일수록 FFHQ 이미지 분포를 벗어난다. 세기 0.25에서 고정- r 어댑터는 FID 102.43, 다양성 0.7689에 이르는데, 차단 반경은 전 구간에서 FID가 50.13–57.40에 머물고 다양성은 최대 0.5066다. 무작위- r 어댑터를 줄이면 FID가 오르면서 구조가 사라진다(세기 0.50에서 76.46, 고정- r 어댑터는 70.91). 표 11의 촘촘한 스윕은 차단 반경 $r=0.3$ 을 양쪽에서 감싼다. 그 차단 반경은 FID 52.77에서 0.2599를 내며, 모두 $r=0.1$ 에서 채점한 값이다. 세기 0.6은 FID 66.39에서 0.3373를, 세기 0.5은 FID 76.46에서 0.2146를 낸다. 우리는 이 대가를 조건이 약해진 탓이 아니라 학습-추론 불일치로 읽는다. 어댑터는 오직 세기 1.00에서만 학습되므로 추론 시 이를 낮추면 UNet이 한 번도 본 적 없는 상태에 놓이는 반면, r 은 샘플마다 뽑혔으므로 차단 반경을 옮기는 것은 학습 분포 안에 머문다. 그림 5도 이와 맞는다. 세기 0.25에서 두 어댑터 모두 스케일된 skip 경로로 회색조 조건을 여전히 써 넣지만 모델이 그것을 완성하기에는 너무 약해서, 어느 쪽에서든 둘째 행이 회색으로 나온다. 이는 측정된 것이 아니다.

설정	SC	다양성	FID
고정 $r=0.1$ 어댑터, 스케일			
세기 0.25	0.0640	0.7689	102.43
세기 0.50	0.3193	0.5540	70.91
세기 0.75	0.5829	0.4044	57.52
세기 1.00	0.7050	0.2967	48.51
무작위- r 어댑터, $r=0.1$ 에서 스케일			
세기 0.25	0.0408	0.7752	104.95
세기 0.50	0.2146	0.6061	76.46
세기 0.75	0.4893	0.4171	58.90
무작위- r 어댑터, 차단 반경 이동			
$r=0.2$	0.4019	0.3719	53.45
$r=0.3$	0.2347	0.3794	52.77
같은 생성물, 계측기 $r_m=0.1$ 고정			
$r=0.05$	0.6524	0.3126	51.58
$r=0.2$	0.3838	0.3719	53.45
$r=0.3$	0.2599	0.3794	52.77

표 2: 세기와 차단 반경. 스케일한 행은 모두 $r=0.1$ 에서 생성하고 채점했으므로 이미 계측기 $r_m=0.1$ 을 쓴다. 차단 반경을 옮긴 행은 각자의 차단 반경으로 채점했고, 마지막 블록은 같은 생성물을 $r_m=0.1$ 로 다시 채점한 것이다(4.1절). 고정- r 어댑터의 세기 1.00은 4.4절 특화 모델을 따로 추론한 것이다(거기서는 0.7049).

전체 세기에서 고정 $r=0.1$ 어댑터의 FID는 48.51로, 같은 차단 반경의 무작위- r 어댑터 54.68보다 낮다. 그림 5는 스케일 설정이 처음 두 테스트 이미지에서 무엇을 만드는지 보여준다.

4.4 차단 반경별 특화 모델과의 비교

고정 r 로 어댑터 네 개를 한 번씩 학습해, 세 번 학습한 무작위- r 어댑터와 각자의 차단 반경에서 비교했다. 각 격차를 무작위- r 어댑터의 시드 3개 표준편차로 나누고, 그 비가 $df = 2$ 의 양측 t 임계값(4.303)보다 작으면 구별되지 않는다고 본다. 특화 모델은 각각 한 번의 실행이므로 이 기준은




그림 4: 위: 차단 반경에 대한 구조 순응도와 표본 다양성(표 1의 값이며 SEM과 시드 sd도 거기에 있다). 아래: 구조 순응도에 대한 FID, 점마다 FID 추정은 하나다. 채운 사각형은 $r \in [0.05, 0.3]$ 에서 자기 차단 반경으로 채점한 스왑, 빈 회색 사각형은 같은 스왑의 구간 밖이다. 마름모는 같은 생성물을 제측기 $r_m=0.1$ 로 다시 채점한 것이다. 원과 삼각형은 무작위- r 어댑터와 고정- $r=0.1$ 어댑터를 $r=0.1$ 에서 스케일한 것으로, 이미 $r_m=0.1$ 을 쓴다. 그 한 제측기에서 차단 반경 $r=0.3$ 은 FID 52.77에서 0.2599에, 세기 0.50은 FID 76.46에서 0.2146에 이른다. 두 패널 모두 평가 출력에서 직접 그렸다.

새 실행에 대한 예측구간보다 느슨하다. 결과는 엇갈린다. $r=0.1$ 에서는 특화 모델이 이기고 (0.7049 대 0.6245, $\Delta = +0.0803$, $+13.55$ sd), $r=0.3$ 에서는 무작위- r 어댑터가 이긴다(0.2318 대 0.1214, -0.1104 , -10.42 sd). $r=0.5$ (-1.00 sd)와 $r=0.7$ ($+0.14$ sd)은 구별되지 않는다(표 12).

모델 하나가 넷을 압도하지는 않는다. $r=0.1$ 로 학습한 특화 모델은 $r=0.3$ 을 본 적이 없으므로, r 축 위에서는 동작점 하나만 제공하는 반면 무작위- r 어댑터는 구간을 제공한다.

4.5 베이스라인

같은 테스트 이미지와 캡션에서 사전학습 ControlNet [55]과 T2I-Adapter-Canny [28]에 비교했다. 모든 베이스라인에 Canny 엣지(임계 100, 200)를 조건 스케일 1.0으로 주고, 파이프라인 기본 PNDM 샘플러, 50스텝, CFG 7.5, 시드 2026을 썼다. 표 3가 이를 DDIM으로 샘플링하는 $r=0.1$ 의 우리 어댑터와 나란히 실는다. ControlNet-HED 체크포인트는 HED 경계가 아니라 같은 Canny 엣지를 받았다. T2I-Adapter-Canny는 결가지 네트워크라 복제 인코더보다 우리 설계에 가깝다. 두 가지 비대칭 때문에 이는 동일 조건 비교가 아니라 동작점 비교다. 조건이 다르고(Canny 엣지 대 주파수 대역), 우리 어댑터는 FFHQ 65,100장으로 학습한 반면 ControlNet은 여기서 제로샷이며 FID도 FFHQ 통계 대비다. 텍스트 정합에서는 ControlNet-Canny의 CLIP 30.34가 우리의 전 구간 최고값 30.30보다 높다. T2I-Adapter의 스케치 체크포인트는 PiDiNet 스케치를 입력으로 기대하므로

방법	샘플러	파라미터	Edge-F1	LPIPS	FID	CLIP
ControlNet-Canny	PNDM	361,279,120	0.6854	0.5294	71.92	30.34
ControlNet-HED, Canny 입력	PNDM	—	0.5733	0.6548	118.98	29.16
T2I-Adapter-Canny	PNDM	77,000,640	0.5845	0.5690	86.66	30.58
우리, $r=0.1$	DDIM	6,611,469	0.7439	0.3748	54.68	29.53

표 3: Canny 엣지를 받은 사전학습 베이스라인과 $r=0.1$ 의 우리 어댑터. 같은 테스트 500장과 캡션, 50스텝, CFG 7.5, 시드 2026이다. 파라미터는 ControlNet-Canny와 우리는 학습 파라미터, T2I-Adapter는 결가지 네트워크 파라미터다. 샘플러가 다르므로 각 행은 동작점이며 동일 조건 비교가 아니다.

제외했다. Canny 엣지를 넣으면 방법이 아니라 그 불일치를 제거 된다.

4.6 학습 도메인 밖

지금까지는 전부 FFHQ다. 다이얼이 얼굴에만 국한되는지 보려고 Hugging Face의 공개 사진-스케치 세트 rhfeiyang/photo-sketch-pair-500(데이터셋 카드에 라이선스도 원출처도 적혀 있지 않다)에 있는 일반 장면 사진 500장을 512²로 가운데 잘라 스왑을 돌렸고, 같은 스크립트의 도메인 내 기준으로 FFHQ 테스트 이미지 500장에도 돌렸다. 둘 다 프롬프트는 “a high-quality photo”다. 각 생성물은 두 가지로 채점한다. 회색조 출력과 회색조 입력 사진의 상관, 그리고 회색조 출력과 모델이 받은 필터된 조건의 상관이다. 둘 다 출력이 필터를 적용하지 않으므로 표 1의 구조 순응도 제측기가 아니며, 도메인 내 값도 표 1과 다르다(표 13).

입력 사진 대비 점수는 도메인 밖에서 $r=0.05$ 의 0.4506에서 $r=0.3$ 의 0.1384로, 도메인 내에서 0.5981에서 0.4142로 떨어진다. 필터된 조건 대비로는 도메인 밖에서 0.3139에서 0.0303로, 도메인 내에서 0.3193에서 0.0334로 떨어진다. 다이얼은 도메인 밖으로 이어진다. 어댑터를 끄면 도메인 밖 이미지는 $r=0.1$ 에서 입력 사진 대비 0.0145를 기록한다(컷면 0.3106).

화질은 전이되지 않는다. 각 실행을 자기 입력 사진에 대해 켜 FID가 $r=0.1$ 에서 도메인 내 65.71에서 도메인 밖 148.97로 오른다. 필터된 조건 대비로는 같은 두 실행이 0.1796와 0.1830를 기록하며, 모든 차단 반경에서 이만큼 가깝게 붙어 있다. 둘 다 우연 수준을 크게 웃돈다. 같은 생성물을 다른 입력의 필터된 조건에 대해 채점하면 $r=0.1$ 에서 0.0015와 0.0018에 그치고, 두 실행의 어떤 관독도 자기 바닥값보다 35 표준오차 이상 떨어져 있지 않은 경우가 없다. 따라서 조건 추종과 화질은 따로 움직인다. 우리가 주장하는 구간에서 다이얼은 학습 도메인 밖에서도 안에서와 비슷하게 구조를 붙잡는 반면 FID는 전이되지 않는다.

4.7 손으로 그린 스케치

그림 6이 전이 결과다. 공개 HuggingFace 세트 a573p/Face-Sketches40의 실제 얼굴 그림 전부인 40장을 쓴다. 카드는 이를 CUHK 얼굴 스케치 데이터베이스의 이미지라고 설명하며 라이선스는 적지 않는다. 스캔마다 FERET 파일명이 찍혀 있으므로, 이들은 CUFS의 사진 하위집합이 아니라 FERET 사진으로 만든 CUFSF 세트 [47, 57]에서 온 것이다. 학습에



그림 5: 처음 두 테스트 이미지에 대한 어댑터 세기와 차단 반경. 샘플링 시드 2026과 BLIP 캡션을 전체에 걸쳐 고정했다. 2-5열은 고정- $r=0.1$ 특화 모델을 세기 1.00에서 0.25까지 스케일한 것이다(표 2). 6-7열은 무작위- r 어댑터를 $r=0.1$ 에서 0.50과 0.25로 스케일한 것이다. 8-9열은 같은 어댑터를 전체 세기로 $r=0.1$ (표 1)과 $r=0.3$ 에서 돌린 것으로, 그림 3과 같은 생성물이다. 세기 0.75의 고정- r 어댑터는 여전히 참조를 따른다. 어느 어댑터든 세기를 0.50으로 낮추면 배경과 색이 바뀌고 둘째 행은 자세도 바뀐다. 0.25에서는 두 행 모두 자세와 구도가 바뀌고 둘째 행은 회색조가 된다. 차단 반경을 $r=0.3$ 으로 옮기면 참조의 배치가 유지된다. 모든 출력은 이 논문이 다루는 모델이 생성한 것이다.



그림 6: 얼굴 그림 40장 중 파일 순서로 처음 네 장(윗줄)과, 주 모델이 그에 대해 낸 무보정 제로샷 출력(아랫줄; 프롬프트 “a high-quality photo of a face”). 그림에는 차단 반경이 없으므로 모델이 그림 자체에서 구조 밀도를 읽어와야 하며, 이미지별 최소-최대 정규화가 이를 가능하게 한다. 스캔 대부분은 상단에 보관용 파일명이 적혀 있고 모델은 그것까지 다시 그린다. 주어진 조건을 문자 그대로 따른 것이다. 그 때를 넘어서는 대로 프레임 상단 20%(102행)를 통째로 제외하면 점수는 0.5398이 된다(-0.0086, 표준오차 0.32배). 즉 점수가 재는 것은 그 때가 아니다.

쓰인 적 없는 이 그림들을 “a high-quality photo of a face” 프롬프트로 넣으면, 회색조 출력과 입력 그림의 상관은 0.5484, CLIP 점수는 23.43이다. FID는 보고하지 않는다. 40장은 안정적인 추정에 부족하고, 평가가가 값을 내는 대신 거부한다. 같은 Hugging Face 사진-스케치 세트 rhfeiyang/photo-sketch-pair-500의 스케치 절반인 일반 장면 그림 500장도 같은 얼굴 프롬프트로 돌렸다. 학습 도메인에서 크게 벗어난 이 경우 그 상관은 0.1714로 떨어지고 FFHQ 대비 FID는 285.91다. 모델이 그림은 따르지만 얼굴을 만들지 못한다. 얼굴만 학습했기 때문이다.

스케치 기반 얼굴 편집은 이전에도 그림의 역할을 나눠 왔다. 기하는 스케치에서, 외양은 참조에서 가져오거나 [3], 따로 적용할 수 있는 스케치 개념들로 조깅다 [49]. 차단 반경은 이를 주파수로 나누며 참조 이미지를 필요로 하지 않는다.

그림에는 차단 반경이 없지만 작가가 줄 수 있다. 그림을 r 로 걸러 모델에 넣으면 되고, 이는 모든 학습 조건이 거친 연산과 같다. 얼굴 그림 40장에서 회색조 출력과 원래 그림의 상관은 $r=0$ 의 0.5486에서




그림 7: 오토인코더에 넣은 조건과, 인코딩-디코딩 왕복 후 다시 추출한 조건 사이의 상관. FFHQ-512 파일 순서로 처음 24장이며 테스트 split이 아니다. $r \approx 0.5$ 위에서는 조건이 사실상 사라진다. 조건을 256에서 만들어 확대하면 구조가 더 낮은 절대 주파수에 놓여 훨씬 많이 보존되며, 예전 파이프라인과 비교할 때 소스 해상도를 명시해야 하는 이유다.

$r=0.1$ 의 0.3390, $r=0.3$ 의 0.2271, $r=1$ 의 0.0407로 떨어진다. $r=0.5$ 와 $r=0.7$ 은 서로 표준오차(0.0419) 안에 있다. 측정이 아니라 의도된 용도로 적자면, $r=0.05$ 는 어댑터가 붙잡을 수 있는 만큼 얼굴을 그대로 붙잡고 싶을 때, $r=0.3$ 은 배치는 지키되 세부들 다시 그리고 싶을 때, 그보다 위는 배치 자체를 놓아줄 때다. r 을 한 번 바꾸는 비용은 재생성 한 장, H200 한 장에서 1.88초다(표 15).

실제로 받은 필터된 그림에 대해 채점하면 같은 생성물이 $r=0.05$ 에서 0.2552, $r=0.1$ 에서 0.1399, $r=0.3$ 에서 0.0142다. 같은 스크립트로 “a high-quality photo” 프롬프트를 준 FFHQ 테스트 사진 500장은 0.3193, 0.1796, 0.0334에 이르므로(4.6절), 필터된 그림은 모든 차단 반경에서 필터된 사진보다 덜 충실하게 따라진다. $r=0.3$ 에서 그림의 점수는 사진의 절반에 못 미친다(0.0142 대 0.0334). 다만 프롬프트와 세트 크기가 다르다(표 14).

5 설계에 필요한 것

5.1 동결 VAE를 통과하는 조건의 양

그림 7는 고주파 조건이 동결 SD VAE를 얼마나 통과하는지 잴다. 인코딩-디코딩 왕복 후 다시 추출한




그림 8: 두 주입 경로를 모두 켜 경우, 각각 단독, 그리고 둘 다 끈 경우. skip 잔차가 구조 신호의 대부분을 나르고, 교차 어텐션 단독으로는 거의 회복하지 못하며, 둘 다 끄면 동결 백본으로 떨어진다(FID 120.50, 양쪽 켜올 때는 50.13, skip만 65.12, 어텐션만 67.07). 점선은 $r=0$ 에서 양쪽을 끈 대조군이다. 경로는 학습된 주 모델에서 추론 시에 끈 것이며, 따로 학습한 skip 단독 모델은 표 6에 있다. $r=0$ 에서는 대조군 대비 단일 경로 이득의 합이 양쪽 경로 이득과 대략 같고, $r=0.3$ 에서는 양쪽 경로의 이득이 단일 경로 이득의 합을 넘는다.

조건은 원래 조건과 $r=0.1$ 에서 0.8562, $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700의 상관을 보인다. 왕복은 잠재가 보존하는 양의 하한이다. 잠재에는 남아 있으나 동결 디코더가 그리지 못하는 성분이 있을 수 있다. 표 4의 동결 VAE 설계는 어텐션으로만 주입하며 $r=0.1$ 에서 구조 순응도 0.0177에 이르는데, 그 차단 반경에서 왕복은 여전히 0.8562의 상관을 유지한다. 따라서 왕복에서의 조건 손실만으로는 그 결과를 설명할 수 없다. IP-Adapter [52] 같은 이미지 프롬프트 설계는 CLIP 이미지 임베딩을 읽으므로 이 측정은 그것에 대해 말하지 않는다. 조건을 256에서 만들어 업샘플하면 구조가 더 낮은 절대 주파수로 옮겨가고, 왕복은 원래 해상도의 0.5773 대신 $r=0.3$ 에서 0.7978를 남긴다. 예전 설정과 비교할 때 알아둘 만한 데이터 파이프라인 인공물이다.

5.2 어디에 주입할 것인가

표 4는 절대 구성을 나열한다. 대조군 아래의 각 행은 **conv / attn** 행에서 한 필드를 바꾼 것인데, 0초기화 게이트가 없는 동결 VAE 행만 두 필드를 바꾼다. 그림 8은 추론 시 경로를 꺼서 주 모델을 분해한다. 교차 어텐션만 남기면 $r=0$ 의 SC가 0.6991에서 0.2112로 떨어지고, skip 경로만 남기면 0.5370가 유지된다. 두 경로를 모두 끄면 SC 0.0368, FID 120.50로 떨어지며, 이것이 어댑터가 일을 하고 있다는 대조군이다. 두 단일 경로는 FID에서는 가깝고(65.12 대 67.07) SC에서는 멀다. 두 경로가 합쳐지는 방식도 차단 반경에 따라 달라진다. $r=0$ 에서는 각 경로의 대조군 대비 이득이 대체로 더해지는 반면, $r=0.3$ 에서는 둘을 함께 켜 이득이 그 합을 넘는다. 우리는 이를 조건이 뺄뺄할 때는 두 경로가 같은 정보를, 회복할 때는 서로 다른 정보를 나르기 때문으로 읽는다. skip 잔차가 국소 디테일을 놓고 교차 어텐션이 그것이 어디로 갈지를 말한다. 이는 측정한 것이 아니다.

어텐션 단독 설계 안에서 128채널 스템은 $r=0.05$ 의 SC를 0.1485에서 0.2826로 올리고, 256채널 스템은 학습 파라미터 6,998,637개로(스템이 없으면 405,613개) 0.2986에 이른다. skip 경로만 6,205,856개 파라미터로 학습하면 0.7085에 이른다(5.3절). 7×7

조건 인코더	주입	SC $r=0.05$	SC $r=0.1$	FID $r=0.1$
어댑터 없음 (대조군)		0.0074	0.0082	120.50
동결 VAE	attn, 0초기화 게이트 없음	0.0234	0.0147	76.25
동결 VAE	attn	0.0303	0.0177	65.71
conv	attn	0.1485	0.0772	56.39
conv + 128채널 스템	attn	0.2826	0.1882	53.17
conv + 256채널 스템	attn	0.2986	0.2158	52.84
conv	attn, 7×7	0.0359	0.0218	58.51
conv	attn + skip	0.7469	0.6211	54.68

표 4: 누적 사슬이 아니라 절대 구성이다. 대조군 아래 각 행은 **conv / attn** 행과 정확히 한 필드가 다르며, 명시하지 않는 한 모두 3×3 창과 0초기화 게이트를 쓴다. 주 모델은 마지막 행이고 스템이 없으며, 어텐션 지점은 인코더 출력을 1×1 투영으로 읽는다. 동결 VAE 행은 어텐션으로만 주입한다. 이 행들과 7×7 행은 두 차단 반경 모두에서 어댑터 없음 대조군에 가까우므로, 그 수준에서는 약한 실재와 학습에 실패한 실행을 구별할 수 없다. skip 경로를 켜 상태의 스템 폭 변화는 표 5에 있다.

창은 0.0359로 3×3 설계(0.1485)보다 한참 낮고 어댑터 없음 대조군(0.0074)에 가깝다. 이 행들은 모두 skip 경로 없이 용량을 바꾼 것이므로 어텐션 단독 설계 안에서의 용량을 잴다.

표 5은 두 경로를 모두 켜 주 모델에서 한 필드씩 바꾼 어블레이션이다. 각각 시드 하나이므로 차단 반경별 주 모델의 시드 3개 퍼짐($r=0$ 에서 0.0105, $r=0.05$ 에서 0.0015)에 비추어 방향만 읽는다. 여기서도 용량이 돕는다. $r=0$ 에서 256채널 스템은 SC를 0.6991에서 0.7900로 올리며 이는 그 지점 시드 퍼짐의 몇 배다. 어텐션 단독에 skip 경로를 더하면 0.2112에서 0.6991로 오른다. $r=0.05$ 에서는 스템의 이득이 줄고(0.7469 $\rightarrow$ 0.7631), $r=0.1$ 의 FID는 54.68에서 51.36로 내려간다. 어텐션 창은 돕지 않는다. 1×1 은 표의 모든 차단 반경에서 3×3 과 시드 퍼짐 안에서 같거나 더 높고, 5×5 는 모두 낮다. 어텐션 지점이 기여하는 것은 이웃이 아니라 조건이 들어가는 위치다. 0초기화 게이트는 유지할 가치가 있다. 없으면 $r=0$ 부터 0.3까지 SC가 낮고 $r=0.1$ 의 FID가 높다. 가장 큰 단일 변화는 r 를 뽑는 방식이다. 로그-균등 샘플러는 $r=0$ 의 SC를 0.9480로 올리고 FID를 42.06로 낮추지만 윗구간을 내준다($r=0.5$ 에서 0.0858 대 0.1259). 다이얼을 전 구간에서 개선한다기보다 해상도를 작은 r 쪽으로 옮기는 것이다. 위의 결과는 모두 균등 샘플러로 얻었다. 1×1 과 스템 변형이 표 5의 여러 차단 반경에서 더 높은데도 주 모델이 3×3 창과 스템 없음을 유지하는 것은, 이 단일 필드 어블레이션을 주 구성과 그 시드 3개를 확정한 뒤에 학습했기 때문이다. $r=u^2$ 샘플러도 마찬가지다. 이 샘플러는 학습을 작은 r 에 몰고, 주장하는 구간의 측정된 모든 차단 반경에서 주 모델보다 높은 구조 순응도를 낸다(표 5, 7). FID는 $r=0.1$ 에서 더 낮고 $r=0.05$ 와 0.3에서는 단일 추정 잡음 안에 있다(표 8). 우리는 이를 채택하지 않고 어블레이션으로 둔다. 샘플러는 이 절이 바뀌 보는 필드 중 하나이고, 이 수치들을 보고 고르는 것은 테스트 집합 위에서 고르는 일이 되기 때문이다.

5.3 skip 경로 단독

5.2절은 두 경로를 모두 학습한 모델에서 주입 경로를 꺼 본 것이다. 그러면 위치와 용량이 섞인다. 교차

바꾼 필드	SC				FID
	$r=0$	0.05	0.3	0.5	$r=0.1$
주 모델	0.6991	0.7469	0.2347	0.1259	54.68
시드 sd (3개)	0.0105	0.0015	0.0106	0.0093	-
1×1 창	0.7825	0.7640	0.2271	0.1255	55.70
5×5 창	0.6764	0.7175	0.2039	0.0944	55.68
0초기화 게이트 없음	0.6838	0.7322	0.2058	0.1290	57.02
평균 풀링 축소	0.7203	0.7465	0.2279	0.1241	55.13
64채널 스템	0.7775	0.7594	0.2354	0.1170	51.91
256채널 스템	0.7900	0.7631	0.2511	0.1214	51.36
컬러 조건	0.6949	0.7463	0.2343	0.1255	54.75
조건 드롭아웃 없음	0.7042	0.7353	0.2279	0.1231	54.69
$r=u^2$ 샘플러	0.8936	0.7836	0.2468	0.1039	53.46
로그-균등 샘플러	0.9480	0.8000	0.2302	0.0858	54.87

표 5: 주 모델에서 한 필드씩 바꾼 어블레이션. skip과 어텐션 경로를 모두 켜고 각각 학습 시드 하나다. 둘째 행은 주 모델의 시드 3개에 대한 퍼짐이다. 주 모델은 3×3 창, 0초기화 게이트, 어텐션 지점마다 조건 특징을 학습형 2×2 스트라이드로 축소, 1×1 투영 앞의 스템 없음, 회색조 조건, 조건 드롭아웃 0.05, [0, 1] 균등 r 을 쓴다. u 를 균등하게 뽑아 $r = u^2$ 로 두면 작은 r 에 학습이 몰리고, $[10^{-3}, 1]$ 로그-균등 샘플러는 더 강하게 몰린다.

r	skip 단독	두 경로	어텐션 단독
0.05	0.7085	0.7469	—
0.10	0.5765	0.6211	0.0275
0.20	0.3508	0.4019	—
0.30	0.1608	0.2347	0.0279
0.50	0.0709	0.1259	—
0.70	0.0757	0.1110	—

표 6: skip 경로만으로 학습한 모델의 구조 순응도를 주 모델, 그리고 그 교차 어텐션 분기를 따로 켜 값과 비교했다. 마지막 열은 추론 시 경로를 끈 값이므로 처음부터 학습한 비교가 아니다.

어텐션 분기가 여전히 존재하고 학습돼 있으며 추론 시 꺼졌을 뿐이기 때문이다. 그래서 어텐션 분기를 아예 제거하고 skip 경로만 처음부터 학습시켰다.

$r=0.1$ 에서 SC 0.5765에 도달하며, 두 경로를 쓴 0.6211, 교차 어텐션 단독 0.0275와 비교된다. FID는 54.68 대비 58.20다. 단독으로 학습한 skip 경로는 주 모델의 대부분을 회복하지만 전부는 아니므로, 어텐션 분기는 skip 경로가 주지 못하는 무언가를 더한다. skip 단독 모델의 학습 파라미터는 두 경로 모델의 6,611,469개 대비 6,205,856개이고, 256채널 스템을 쓴 어텐션 단독 설계는 6,998,637개 파라미터로 $r=0.1$ 에서 0.2158에 이른다(표 4). 전체 곡선은 표 6에 있다.

6 한계

여기 있는 모든 것은 한 도메인(FFHQ 얼굴)과 한 백본(SD1.5)이며, 세 결과가 그 백본에 의존하는 정도는 다르다. 다이얼은 조건만으로 정의되며, 우리는 SD1.5와 FFHQ-512에서 켜다. SDXL [36]은 UNet skip 텐서를 유지하므로 가장 가까운 다음 시험 대상이다. skip 경로 주입은 UNet에 한정된다. MMDiT 백본 [6]에는 UNet식 skip 연결이 없고, 거기서 제어는 공유 토큰이나 LoRA [17] 모듈 [25, 44, 58]로 들어간다. VAE 측정은 4채널 SD 오토인코더에 대한 것이다.

다이얼은 $r \in [0.05, 0.3]$ 에서 주장한다. 그 위에서는 조건에 남은 에너지가 적어($r=0.5$ 에서 상수항 제외 스펙트럼 에너지의 0.0074) 구조 순응도를 해석하기 어려워진다. 거의 비어 있는 두 신호는 모델이 무엇을 하든 상관없이 0에 가깝기 때문이다. FID는 칸마다 추정값이 하나뿐이고 분산이 없으므로 차단 반경 스위치의 대역(50.13–57.40) 안의 차이는 해석하지 않는다. 세기 설정의 FID는 FFHQ 통계 대비로 켜 것이다. 세기 0.50 이하에서 그림 5의 표본은 눈에 띄게 망가지기보다 참조의 배치에서 벗어나므로, FID 상승은 적어도 부분적으로 그 분포를 벗어난 것을 반영하며, 참조 없는 품질 지표는 보고하지 않는다. 표 5의 단일 필드 어블레이션은 단일 시드이고, 조건의 이미지별 정규화는 실제로 정했을까 어블레이션하지 않았다. $r=0.1$ 에서는 고정 차단 반경 특화 모델이 무작위- r 어댑터보다 시드 sd의 +13.55배 앞선다(4.4절). 동결 VAE를 skip 경로와 결합한 적이 없으므로 표 4의 VAE 결과는 어텐션 단독 주입의 약함과 교차되어 있다. 스케치 결과에는 어댑터를 끈 대조군이 없다. ControlNet 비교는 동작점 사이의 비교이며, 우리 조건과 데이터로 학습한 ControlNet이 동일 조건 대조군이 되겠지만 학습하지 않았다. 스케치 신뢰도 제어 [51], 노이즈 수준 편집 [27], 학습 없는 필터 유도 [11], 기하-외양 얼굴 편집 [3]과도 비교하지 않았다. 이들은 입력이 달라 별도의 프로토콜이 필요하다.

어댑터의 학습 파라미터는 6,611,469개로, ControlNet보다 적고 최근 경량 제어 모듈보다 많다. SimpleControlNet [8]은 SD1.5에서 300만 미만을 보고하고, ControlNet-XS [54]는 ControlNet보다 훨씬 작은 제어 네트워크를 쓰며, 위의 DiT 모듈들은 우리의 몇 분의 일을 쓴다. 효율은 주장하지 않는다. 다이얼은 이미지 지표로만 평가했다. r 을 같은 쪽으로 바꾸면 같은 변화로 지각되는지, 작가가 이 제어를 유용하다고 느끼는지는 여기서 측정하지 않았다. 또한 SC도 Edge-F1도 배치와 외양을 분리하지 못하므로, 배치는 유지되고 외양이 변한다는 관찰은 그림 3과 5의 샘플에 근거한다.

7 결론

학습 중 구조 조건의 대역폭을 무작위화하면 차단 반경이 추론 시 제어가 되고, 그 제어는 이 어댑터의 세기를 줄이는 것으로는 재현되지 않는다. 체크포인트 하나가 FID 51.58와 54.68 사이에서 $r \in [0.05, 0.3]$ 을 담당하며, 그 구간에서 우리 샘플은 얼굴 배치를 유지한 채 배경·의복·색이 참조를 덜 따른다. 비슷한 느슨함을 세기로 얻으려면 FID를 치러야 한다(4.3절). 이 체크포인트는 $r=0.1$ 에서 특화 모델에 뒤지고 $r=0.3$ 에서는 앞선다(4.4절). 설계는 조건을 동결 오토인코더가 아니라 합성곱 인코더로 읽고 UNet skip 텐서와 교차 어텐션으로 주입하며, 두 선택 모두 SD1.5에서 측정했다.

A 차단 반경별 전체 결과

본문은 각 실험을 그 논지를 뒷받침하는 차단 반경에서 보고한다. 여기 표들은 측정된 모든 차단 반경을 담았으며, 논문의 나머지와 같은 results.json

파일에서 생성된다. 표 7과 8는 표 5을, 표 9는 표 1을, 표 10는 5.3결과 시드 퍼짐을, 표 11은 4.3절을, 표 12은 4.4절을, 표 13과 14은 4.6결과 손그림 결과를 확장하며, 표 15는 이 모든 결과의 설정을 정리한다.

변형	$r=0$	0.05	0.1	0.3	0.5
주 모델	0.6991	0.7469	0.6211	0.2347	0.1259
1×1 창	0.7825	0.7640	0.6382	0.2271	0.1255
5×5 창	0.6764	0.7175	0.5919	0.2039	0.0944
64채널 스템	0.7775	0.7594	0.6358	0.2354	0.1170
256채널 스템	0.7900	0.7631	0.6332	0.2511	0.1214
평균 풀링 축소	0.7203	0.7465	0.6181	0.2279	0.1241
컬러 조건	0.6949	0.7463	0.6251	0.2343	0.1255
로그-균등 샘플러	0.9480	0.8000	0.6617	0.2302	0.0858
$r=u^2$ 샘플러	0.8936	0.7836	0.6568	0.2468	0.1039
조건 드롭아웃 없음	0.7042	0.7353	0.6108	0.2279	0.1231
0초기화 게이트 없음	0.6838	0.7322	0.6118	0.2058	0.1290
채택하지 않은 설계 (5.1 절)					
256px 소스 파이프라인	—	0.0271	0.0171	0.0291	—
VAE 조건	—	0.0234	0.0147	0.0172	—

표 7: 모든 단일 필드 어블레이션의 구조 순응도, 측정된 모든 차단 반경. 주 모델 아래 첫 블록의 각 행은 주 모델에서 한 필드를 바꾼 것이다. 마지막 블록은 논문이 채택하지 않은 두 설계다. 첫째는 조건을 동결 VAE로 읽는 것으로, 어텐션 단독 주입에 0초기화 게이트가 없다 (표 4의 첫 동결 VAE 행). 둘째는 조건을 256에서 만들어 업샘플하는 것으로, 주입 구성은 첫째와 같고 소스 해상도만 다르다($r=0.1$ 에서 FID 86.84).

변형	$r=0$	0.05	0.1	0.3	0.5
주 모델	50.13	51.58	54.68	52.77	53.97
1×1 창	49.13	52.34	55.70	54.16	54.33
5×5 창	52.05	54.16	55.68	54.43	55.39
64채널 스템	48.92	50.25	51.91	51.08	52.03
256채널 스템	47.74	49.49	51.36	51.77	52.13
평균 풀링 축소	50.90	53.43	55.13	54.29	54.32
컬러 조건	52.53	52.09	54.75	52.67	52.84
로그-균등 샘플러	42.06	52.17	54.87	54.33	56.96
$r=u^2$ 샘플러	44.69	51.89	53.46	52.87	54.52
조건 드롭아웃 없음	51.17	52.50	54.69	53.13	54.26
0초기화 게이트 없음	52.72	55.63	57.02	54.53	55.51

표 8: 표 7과 같은 단일 필드 어블레이션의 FID, 각각 학습 시드 하나. FID는 칸마다 추정값이 하나뿐이고 분산이 없으므로(표 1) 작은 차이를 효과로 읽지 않는다. 가장 크게 벗어나는 것은 $r=0$ 에서의 로그-균등 샘플러와 $r=u^2$ 샘플러다(50.13 대비 42.06, 44.69).

r	SC	FID	LPIPS	CLIP	Edge-F1	다양성
0.00	0.6991	50.13	0.3341	29.54	0.7776	0.2994
0.05	0.7469	51.58	0.3495	29.41	0.7796	0.3126
0.10	0.6211	54.68	0.3748	29.53	0.7439	0.3414
0.20	0.4019	53.45	0.4003	29.47	0.7113	0.3719
0.30	0.2347	52.77	0.4148	29.73	0.6878	0.3794
0.50	0.1259	53.97	0.4418	29.78	0.6225	0.4100
0.70	0.1110	53.69	0.4625	29.92	0.5788	0.4334
1.00	0.0010	57.40	0.5329	30.30	0.4724	0.5066

표 9: 주 모델의 모든 지표, 모든 차단 반경. SC와 FID 열이 그림 4에 그런 값이다.

r	skip 단독	skip 단독 FID	시드 평균	시드 표준편차
0.00	0.6284	55.84	0.7109	0.0105
0.05	0.7085	57.65	0.7479	0.0015
0.10	0.5765	58.20	0.6245	0.0059
0.20	0.3508	57.07	0.4036	0.0098
0.30	0.1608	57.21	0.2318	0.0106
0.50	0.0709	57.41	0.1304	0.0093
0.70	0.0757	57.95	0.1261	0.0186
1.00	0.0006	59.60	0.0012	0.0002

표 10: 왼쪽: skip 경로만 학습한 모델(5.3절). 오른쪽: 주 모델의 시드 2026, 2027, 2028에 대한 구조 순응도 평균과 표준편차.

어댑터 세기	SC	FID	SC, 시드 2027
0.1	0.0165	117.58	—
0.2	0.0300	110.20	—
0.25	0.0408	104.95	0.0309
0.35	0.0808	95.62	—
0.5	0.2146	76.46	0.2038
0.6	0.3373	66.39	—
0.75	0.4893	58.90	0.4823
1.00	0.6211	54.68	—

표 11: $r=0.1$ 에서 무작위- r 어댑터의 세기를 촘촘히 훑은 결과. 1.00 아래의 각 점은 낮아진 구조 순응도의 대가를 FID로 치른다. 차단 반경 다이얼은 $r \in [0.05, 0.3]$ 에서 FID를 51.58와 54.68 사이에 둔다(표 9). 세기 0.25, 0.5, 0.75는 같은 체크포인트에서 샘플링 시드 2027로 반복했다.

하나의 모델, 시드 3개					
r	특화 모델	평균	sd	차이	차이 / sd
0.10	0.7049	0.6245	0.0059	+0.0803	+13.55
0.30	0.1214	0.2318	0.0106	-0.1104	-10.42
0.50	0.1211	0.1304	0.0093	-0.0093	-1.00
0.70	0.1287	0.1261	0.0186	+0.0026	+0.14

표 12: 차단 반경별 특화 모델(각각 학습 한 번, 시드 2026)과 학습 시드 2026–2028 평균의 무작위- r 모델 하나를 각자의 차단 반경에서 비교했다. 차이는 특화 모델에서 시드 3개 평균을 뺀 값이고, 마지막 열은 그것을 시드 3개 표준편차로 나눈 뒤 4.4절의 기준 4.303과 견준 값이다. 그 기준은 한 번의 새 실행에 대한 예측구간보다 느슨하다. 양수는 특화 모델이 유리함을 뜻한다. $r=0.1$ 에서는 특화 모델이, $r=0.3$ 에서는 하나의 모델이 이기고, $r=0.5$ 와 0.7에서는 구별되지 않는다. 특화 모델이 줄 수 없는 것은 곡선의 나머지다.

도메인 밖			FFHQ 테스트		
r	입력 대비	필터 대비	FID	입력 대비	필터 대비
0.05	0.4506	0.3139	128.40	0.5981	0.3193
0.10	0.3106	0.1830	148.97	0.5057	0.1796
0.20	0.1944	0.0873	154.24	0.4407	0.0799
0.30	0.1384	0.0303	160.82	0.4142	0.0334

표 13: 일반 장면 사진 500장과 FFHQ 테스트 이미지 500장을 같은 스크립트, 프롬프트 “a high-quality photo”로 돌린 결과(4.6절). “입력 대비”는 회색조 출력과 회색조 입력 사진의 상관, “필터 대비”는 모델이 받은 필터된 조건과의 상관이다. 둘 다 출력에 필터를 적용하지 않으므로 표 1의 구조 순응도 값이 아니다. 각 FID는 그 실행의 입력 사진에 대한 값이다. 제어는 두 경우 모두 떨어지고, 화질은 전이되지 않는다.

r	얼굴 스케치 40장			FFHQ 테스트 사진	
	원본 대비	$\pm$ SEM	필터 대비	원본 대비	필터 대비
0.00	0.5486	0.0273	0.5486	—	—
0.05	0.4826	0.0295	0.2552	0.5981	0.3193
0.10	0.3390	0.0356	0.1399	0.5057	0.1796
0.20	0.2746	0.0360	0.0590	0.4407	0.0799
0.30	0.2271	0.0364	0.0142	0.4142	0.0334
$r > 0.3$					
0.50	0.1379	0.0419	0.0013	—	—
0.70	0.1232	0.0419	0.0005	—	—
1.00	0.0407	0.0326	0.0000	—	—

표 14: 손으로 그린 얼굴 스케치 40장에 다이얼을 적용한 결과(주 모델, 샘플링 시드 2026, 프롬프트 “a high-quality photo of a face”). “원본 대비”는 회색조 출력과 필터하지 않은 그림의 상관, “필터 대비”는 모델이 받은 r 로 거른 그림과의 상관이다. 둘 다 출력에 필터를 적용하지 않으므로 표 1의 구조 순응도 계측기가 아니다. 사진 열은 같은 스크립트를 프롬프트 “a high-quality photo”로 FFHQ 테스트 이미지에 돌린 값이다(표 13). $r=0$ 형은 그림 6의 제로샷 평가(거기서는 0.5484)를 독립적으로 다시 돌린 것이다. 스케치에서는 특화 모델을 돌리지 않았다.

B 재현성

항목	설정
기반 모델	stable-diffusion-v1-5/stable-diffusion-v1-5, 동결
조건 인코더	3×3 합성곱 7개, SiLU, 그중 3개는 스트라이드 2와 그들 정규화, 32–128채널, 출력 4채널
학습 파라미터	6,611,469(주 모델), skip 단독 6,205,856, 어텐션 단독 405,613
데이터	FFHQ-512, 65,100 / 1,400 / 3,500, 시드 2026 셔플. 검증 세트는 이미지 4장으로 학습 모니터링에만 사용
스케치 데이터	a573p/Face-Sketches40 전체 40장과 rhfeiyang/photo-sketch-pair-500. 어느 카드에도 라이선스 표기가 없다
최적화	AdamW, 학습률 10^{-4} , $\beta=(0.9, 0.999)$, 가중치 감쇠 0.01, 코사인, 워업 500스텝
배치/정밀도	32 / bf16, 기울기 클리핑 1.0, 12에폭, Min-SNR $\gamma=5$, H200 한 장
연산량	H200 한 장에서 학습 1회 5.7시간, 초당 39장, 최대 61 GB. 샘플링은 장당 1.88초(DDIM 50, CFG 7.5, 배치 1, 512px), 최대 2.9 GB. 학습 26회에 156 GPU-시간, 생성한 186,160장에 측정 속도 기준 약 97시간을 더해 모두 253시간
EMA	감쇠 0.9999, 10스텝마다. 평가는 원래 가중치
드롭아웃	텍스트 0.1, 구조 조건 0.05
학습 시드	주 모델 2026, 2027, 2028. 특화 모델, 어블레이션, skip 단독은 2026
샘플링	DDIM 50스텝, CFG 7.5, 시드 2026. 다양성 시드는 이미지 i 마다 $2026+10^5+i$
평가	테스트 3,500장 중 처음 500장. clean-FID clean 모드 512px, 참조 대비 LPIPS AlexNet, CLIP ViT-B/32(OpenAI 가중치) 코사인의 100배
베이스라인	l1lyasviel/sd-controlnet-canny, l1lyasviel/sd-controlnet-hed, TencentARC/t2iadapter_canny_sd15v2. 모두 Canny 100/200, 조건 스케일 1.0, 기본 PNDM 샘플러, 50스텝, CFG 7.5, 시드 2026
소프트웨어	Python 3.12.3, PyTorch 2.10 (NGC 25.11), diffusers 0.32.2, clean-fid 0.1.35, lpips 0.1.4, open_clip 2.30.0

표 15: 모든 표의 설정. 실행 매니페스트와 평가 스크립트에서 읽었다.

참고문헌

- [1] Soonmin Bae, Sylvain Paris, and Frédo Durand. Two-scale tone management for photographic look. *ACM Transactions on Graphics*, 25(3): 637–645, 2006. doi: 10.1145/1141911.1141935.
- [2] Shu-Yu Chen, Wanchao Su, Lin Gao, Shihong Xia, and Hongbo Fu. Deepfacedrawing: Deep generation of face images from sketches. *ACM Transactions on Graphics*, 39(4), 2020. doi: 10.1145/3386569.3392386.
- [3] Shu-Yu Chen, Feng-Lin Liu, Yu-Kun Lai, Paul L. Rosin, Chunpeng Li, Hongbo Fu, and Lin Gao. Deepfacediting: Deep face generation and editing with disentangled geometry and appearance control. *ACM Transactions on Graphics*, 40(4): 1–15, 2021. doi: 10.1145/3450626.3459760.
- [4] Shin-I Cheng, Yu-Jie Chen, Wei-Chen Chiu, Hung-Yu Tseng, and Hsin-Ying Lee. Adaptively-realistic image generation from stroke and sketch with diffusion model. In *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 4054–4062, 2023. doi: 10.1109/WACV56688.2023.00404.
- [5] Jooyoung Choi, Sungwon Kim, Yonghyun Jeong, Youngjune Gwon, and Sungroh Yoon. Ilvr: Conditioning method for denoising diffusion probabilistic models. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 14367–14376, 2021. doi: 10.1109/ICCV48922.2021.01410.
- [6] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling rectified flow transformers for high-resolution image synthesis. In *Proceedings of the International Conference on Machine Learning (ICML)*, volume 235, pages 12606–12633, 2024. URL <https://proceedings.mlr.press/v235/esser24a.html>.
- [7] Zeev Farbman, Raanan Fattal, Dani Lischinski, and Richard Szeliski. Edge-preserving decompositions for multi-scale tone and detail manipulation. *ACM Transactions on Graphics*, 27(3), 2008. doi: 10.1145/1360612.1360666.
- [8] Zhida Feng, Li Chen, Yuenan Sun, Jiaxiang Liu, and Shikun Feng. Simplifying control mechanism in text-to-image diffusion models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 3013–3021, 2025. doi: 10.1609/aaai.v39i3.32309.

- [9] Xiang Gao and Jiaying Liu. Fbsdiff: Plug-and-play frequency band substitution of diffusion features for highly controllable text-driven image translation. In *Proceedings of the 32nd ACM International Conference on Multimedia*, pages 4101–4109, 2024. doi: 10.1145/3664647.3681380.
- [10] Xiang Gao, Zhengbo Xu, Junhan Zhao, and Jiaying Liu. Frequency-controlled diffusion model for versatile text-guided image-to-image translation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 1824–1832, 2024. doi: 10.1609/aaai.v38i3.27951.
- [11] Zeqi Gu, Ethan Yang, and Abe Davis. Filter-guided diffusion for controllable image generation. In *ACM SIGGRAPH 2024 Conference Papers*, pages 1–10, 2024. doi: 10.1145/3641519.3657489.
- [12] Tiankai Hang, Shuyang Gu, Chen Li, Jianmin Bao, Dong Chen, Han Hu, Xin Geng, and Bain-ing Guo. Efficient diffusion training via min-snr weighting strategy. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 7407–7417, 2023. doi: 10.1109/ICCV51070.2023.00684.
- [13] Yinxi He, Kang Liao, Chunyu Lin, Tianyi Wei, and Yao Zhao. Structdiff: A structure-preserving and spatially controllable diffusion model for single-image generation. *IEEE Transactions on Multimedia*, pages 1–12, 2026. doi: 10.1109/tmm.2026.3716757.
- [14] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. Gans trained by a two time-scale update rule converge to a local nash equilibrium. In *Advances in Neural Information Processing Systems*, volume 30, pages 6626–6637, 2017. URL <https://proceedings.neurips.cc/paper/2017/hash/8a1d694707eb0fefe65871369074926d-Abstract.html>.
- [15] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv:2207.12598*, 2022. URL <https://arxiv.org/abs/2207.12598>.
- [16] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/4c5bcfec8584af0d967f1ab10179ca4b-Abstract.html>.
- [17] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022. URL <https://iclr.cc/virtual/2022/poster/6319>.
- [18] Chao Huang, Susan Liang, Yunlong Tang, Jing Bi, Li Ma, Yapeng Tian, and Chenliang Xu. Fresca: Scaling in frequency space enhances diffusion models. *arXiv:2504.02154*, 2025. URL <https://arxiv.org/abs/2504.02154>.
- [19] Sida Huang, Siqi Huang, Ping Luo, and Hongyuan Zhang. Laytrol: Preserving pretrained knowledge in layout control for multimodal diffusion transformers. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 40, pages 5113–5121, 2026. doi: 10.1609/aaai.v40i7.37425.
- [20] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4401–4410, 2019. doi: 10.1109/CVPR.2019.00453.
- [21] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *Proceedings of the International Conference on Machine Learning (ICML)*, volume 162, pages 12888–12900, 2022. URL <https://dblp.org/rec/conf/icml/0001LXH22.html>.
- [22] Ming Li, Taojiannan Yang, Huafeng Kuang, Jie Wu, Zhaoning Wang, Xuefeng Xiao, and Chen Chen. Controlnet++: Improving conditional controls with efficient consistency feedback. In *Computer Vision – ECCV 2024*, 2024. doi: 10.1007/978-3-031-72667-5_8.
- [23] Yuheng Li, Haotian Liu, Qingyang Wu, Fangzhou Mu, Jianwei Yang, Jianfeng Gao, Chunyuan Li, and Yong Jae Lee. Gligen: Open-set grounded text-to-image generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 22511–22521, 2023. doi: 10.1109/CVPR52729.2023.02156.
- [24] Xin Lin, Haodong Li, Zhifei Zhang, Yutong Yang, Haitian Zheng, Juanxi Tian, Zhe Lin, and Truong Nguyen. Pixelcontrol: Fine-grained condition fidelity in text-to-image diffusion. *arXiv:2608.15705*, 2026. URL <https://arxiv.org/abs/2608.15705>.
- [25] Shanyuan Liu, Jian Zhu, Junda Lu, Yue Gong, Li-uzhuozheng Li, Bo Cheng, Yuhang Ma, Liebuchu Wu, Xiaoyu Wu, Dawei Leng, and Yuhui Yin. Nanocontrol: A lightweight framework for precise and efficient control in diffusion transformer. *arXiv:2508.10424*, 2025. URL <https://arxiv.org/abs/2508.10424>.
- [26] Zehong Ma, Longhui Wei, Shuai Wang, Shiliang Zhang, and Qi Tian. Deco: Frequency-decoupled pixel diffusion for end-to-end image generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern*

- Recognition (CVPR)*, pages 43600–43610, 2026. URL https://openaccess.thecvf.com/content/CVPR2026/html/Ma_DeCo_Frequency-Decoupled_Pixel_Diffusion_for_End-to-End_Image_Generation_CVPR_2026_paper.html.
- [27] Chenlin Meng, Yutong He, Yang Song, Jiaming Song, Jiajun Wu, Jun-Yan Zhu, and Stefano Ermon. Sdedit: Guided image synthesis and editing with stochastic differential equations. In *International Conference on Learning Representations*, 2022. URL <https://arxiv.org/abs/2108.01073>.
- [28] Chong Mou, Xintao Wang, Liangbin Xie, Yanze Wu, Jian Zhang, Zhongang Qi, Ying Shan, and Xiaohu Qie. T2i-adapter: Learning adapters to dig out more controllable ability for text-to-image diffusion models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 4296–4304, 2024. doi: 10.1609/aaai.v38i5.28226.
- [29] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever, and Mark Chen. Glide: Towards photorealistic image generation and editing with text-guided diffusion models. In *Proceedings of the International Conference on Machine Learning (ICML)*, volume 162, pages 16784–16804, 2022. URL <https://proceedings.mlr.press/v162/nichol22a.html>.
- [30] Aude Oliva, Antonio Torralba, and Philippe G. Schyns. Hybrid images. *ACM Transactions on Graphics*, 25(3):527–532, 2006. doi: 10.1145/1179352.1141919.
- [31] Sylvain Paris, Samuel W. Hasinoff, and Jan Kautz. Local laplacian filters: Edge-aware image processing with a laplacian pyramid. *ACM Transactions on Graphics*, 30(4), 2011. doi: 10.1145/2010324.1964963.
- [32] Gaurav Parmar, Richard Zhang, and Jun-Yan Zhu. On aliased resizing and surprising subtleties in gan evaluation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11400–11410, 2022. doi: 10.1109/CVPR52688.2022.01112.
- [33] William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4195–4205, 2023. doi: 10.1109/ICCV51070.2023.00387.
- [34] Bohao Peng, Jian Wang, Yuechen Zhang, Wenbo Li, Ming-Chang Yang, and Jiaya Jia. Controlnext: Powerful and efficient control for image and video generation. *arXiv:2408.06070*, 2024. URL <https://arxiv.org/abs/2408.06070>.
- [35] R. Po, W. Yifan, V. Golyanik, K. Aberman, J. T. Barron, A. Bermano, E. Chan, T. Dekel, A. Holynski, A. Kanazawa, C. K. Liu, L. Liu, B. Mildenhall, M. Nießner, B. Ommer, C. Theobalt, P. Wonka, and G. Wetzstein. State of the art on diffusion models for visual computing. *Computer Graphics Forum*, 43(2):e15063, 2024. doi: 10.1111/cgf.15063.
- [36] Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. Sdxl: Improving latent diffusion models for high-resolution image synthesis. In *International Conference on Learning Representations (ICLR)*, 2024. URL <https://openreview.net/forum?id=di52zR8xgf>.
- [37] Arisha Prasain. Beyond edge maps: Wavelet-domain conditioning for multi-adapter map-to-satellite diffusion. *arXiv:2608.00083*, 2026. URL <https://arxiv.org/abs/2608.00083>.
- [38] Can Qin, Shu Zhang, Ning Yu, Yihao Feng, Xinyi Yang, Yingbo Zhou, Huan Wang, Juan Carlos Niebles, Caiming Xiong, Silvio Savarese, Stefano Ermon, Yun Fu, and Ran Xu. Unicontrol: A unified diffusion model for controllable visual generation in the wild. In *Advances in Neural Information Processing Systems*, volume 36, 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/862f45ccec2275851bc8acebb8b4d65-Abstract-Conference.html.
- [39] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the International Conference on Machine Learning (ICML)*, volume 139, pages 8748–8763, 2021. URL <https://proceedings.mlr.press/v139/radford21a.html>.
- [40] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10684–10695, 2022. doi: 10.1109/CVPR52688.2022.01042.
- [41] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S. Sara Mahdavi, Rapha Gontijo Lopes, Tim Salimans, Jonathan Ho, David J Fleet, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. In *Advances in Neural Information Processing Systems*, volume 35, 2022. URL <https://proceedings>.

- neurips.cc/paper_files/paper/2022/hash/ec795aeadae0b7d230fa35cbaf04c041-Abstract-Conference.html. URL <https://openreview.net/forum?id=AFdXzklaSH>.
- [42] Chenyang Si, Ziqi Huang, Yuming Jiang, and Ziwei Liu. Freeu: Free lunch in diffusion u-net. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4733–4743, 2024. URL https://openaccess.thecvf.com/content/CVPR2024/html/Si_FreeU_Free_Lunch_in_Diffusion_U-Net_CVPR_2024_paper.html.
- [43] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations (ICLR)*, 2021. URL <https://iclr.cc/virtual/2021/poster/2804>.
- [44] Zhenxiong Tan, Songhua Liu, Xingyi Yang, Qiaochu Xue, and Xinchao Wang. Ominicontrol: Minimal and universal control for diffusion transformer. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 14940–14950, 2025. URL https://openaccess.thecvf.com/content/ICCV2025/html/Tan_OminiControl_Minimal_and_Universal_Control_for_Diffusion_Transformer_ICCV_2025_paper.html.
- [45] Gabriel Tjio, Jie Zhang, Xulei Yang, Yun Xing, Nhat Chung, Xiaofeng Cao, Ivor W. Tsang, Chee Keong Kwoh, and Qing Guo. Focus: Frequency-optimized conditioning of diffusion models for mitigating catastrophic forgetting during test-time adaptation. *Machine Vision and Applications*, 37(2), 2026. doi: 10.1007/s00138-026-01786-0.
- [46] Andrey Voynov, Kfir Aberman, and Daniel Cohen-Or. Sketch-guided text-to-image diffusion models. In *SIGGRAPH 2023 Conference Proceedings*, pages 1–11, 2023. doi: 10.1145/3588432.3591560.
- [47] Xiaogang Wang and Xiaoou Tang. Face photo-sketch synthesis and recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31(11):1955–1967, 2009. doi: 10.1109/TPAMI.2008.222.
- [48] Holger Winnemöller, Jan Eric Kyprianidis, and Sven C. Olsen. Xdog: An extended difference-of-gaussians compendium including advanced image stylization. *Computers & Graphics*, 36(6): 740–753, 2012. doi: 10.1016/j.cag.2012.03.004.
- [49] Chufeng Xiao and Hongbo Fu. Customsketching: Sketch concept extraction for sketch-based image synthesis and editing. *Computer Graphics Forum*, 43(7):e15247, 2024. doi: 10.1111/cgf.15247.
- [50] Yifeng Xu, Zhenliang He, Shiguang Shan, and Xilin Chen. Ctrlora: An extensible and efficient framework for controllable image generation. In *International Conference on Learning Representations (ICLR)*, 2025. URL <https://openreview.net/forum?id=AFdXzklaSH>.
- [51] Shuai Yang, Zhangyang Wang, Jiaying Liu, and Zongming Guo. Deep plastic surgery: Robust and controllable image editing with human-drawn sketches. In *Computer Vision – ECCV 2020*, pages 601–617, 2020. doi: 10.1007/978-3-030-58555-6_36.
- [52] Hu Ye, Jun Zhang, Sibao Liu, Xiao Han, and Wei Yang. Ip-adapter: Text compatible image prompt adapter for text-to-image diffusion models. *arXiv:2308.06721*, 2023. URL <https://arxiv.org/abs/2308.06721>.
- [53] Bo Yin, Xiaobin Hu, Xingyu Zhou, Yu He, Peng-Tao Jiang, Yue Liao, Junwei Zhu, Jiangning Zhang, Ying Tai, and Shuicheng Yan. Fera: Frequency-energy constrained routing for effective diffusion adaptation fine-tuning. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. URL <https://icml.cc/virtual/2026/poster/64490>.
- [54] Denis Zavadski, Johann-Friedrich Feiden, and Carsten Rother. Controlnet-xs: Rethinking the control of text-to-image diffusion models as feedback-control systems. In *Computer Vision – ECCV 2024*, 2024. doi: 10.1007/978-3-031-73223-2_20.
- [55] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 3836–3847, 2023. doi: 10.1109/ICCV51070.2023.10377881.
- [56] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 586–595, 2018. doi: 10.1109/CVPR.2018.00068.
- [57] Wei Zhang, Xiaogang Wang, and Xiaoou Tang. Coupled information-theoretic encoding for face photo-sketch recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 513–520, 2011. doi: 10.1109/CVPR.2011.5995324.
- [58] Yuxuan Zhang, Yirui Yuan, Yiren Song, Haofan Wang, and Jiaming Liu. Easycontrol: Adding efficient and flexible control for diffusion transformer. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 19513–19524, 2025. URL https://openaccess.thecvf.com/content/ICCV2025/html/Zhang_EasyControl_Adding_Efficient_and_Flexible_Control_for_Diffusion_Transformer_ICCV_2025_paper.html.

- [59] Shihao Zhao, Dongdong Chen, Yen-Chun Chen, Jianmin Bao, Shaozhe Hao, Lu Yuan, and Kwan-Yee K. Wong. Uni-controlnet: All-in-one control to text-to-image diffusion models. In *Advances in Neural Information Processing Systems*, volume 36, 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/2468f84a13ff8bb6767a67518fb596eb-Abstract-Conference.html.
- [60] Chao Zhou, Tianyi Wei, Yiling Chen, Wenbo Zhou, and Nenghai Yu. Rethinking multi-condition dits: Eliminating redundant attention via position-alignment and keyword-scoping. *arXiv:2602.06850*, 2026. URL <https://arxiv.org/abs/2602.06850>.