

구조 조건부 확산 모델을 위한 주파수 다이얼

익명 제출

Abstract

구조 조건부 확산 어댑터는 하나의 동작점에서 학습된다. Canny 엣지, 깊이 맵, 스케치 — 각각은 출력이 조건을 얼마나 따를지를 고정하고, 그 균형을 옮기려면 다시 학습해야 한다. 우리는 조건의 정보량을 무작위화해 어댑터 하나를 학습한다. 차단 반경 r 을 샘플마다 뽑는 고주파 통과 필터를 쓰고, 추론 시 r 을 다이얼로 되읽는다. FFHQ-512에서 구조 순응도는 $r=0.05$ 의 0.7469에서 $r=0.3$ 의 0.2347까지 내려가고 표본 다양성은 0.3126에서 0.3794까지 올라가며, FID는 그 구간에서 51.58와 54.68 사이에 머문다. 스위치는 $r=1$ 까지 보고하되 다이얼은 $r \in [0, 0.3]$ 에서만 주장한다. 그 위에서는 조건에 남은 에너지가 적어 구조 순응도를 해석할 수 없다. 어댑터 세기는 같은 손잡이가 아니다. 구조 순응도를 맞추면 — 세기 0.50이 0.2146, 차단 반경 $r=0.3$ 이 0.2347 — 세기 설정은 FID 76.46을 쓰고 차단 반경은 52.77를 쓴다. 차단 반경이 두 축에서 동시에 우위다.

구현 과정에서 두 가지를 발견했다. 동결 SD VAE는 어댑터가 읽기 전에 고주파 조건을 과파한다. 인코딩-디코딩 왕복 후 남은 조건은 $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700에 불과하다. 그리고 이 두 주입 설계 사이에서는 위치가 폭보다 중요하다. skip 단독이 SC 0.5370를 유지하는 반면 어텐션 단독은 0.2112이고 양쪽 다 켜면 0.6991다. 어텐션 단독 설계 안에서 어댑터 폭을 네 배로 늘려도 그보다 훨씬 적게 얻는다. 학습 파라미터는 6,611,469개로 ControlNet의 55분의 1이다.

1 서론

ControlNet [34]과 그 후속 연구들 [12, 17, 24, 37]은 조건부 제어를 풀고 그대로 굳혔다. Canny 엣지로 학습한 어댑터는 Canny 엣지를 따르고, 깊이로 학습한 어댑터는 깊이를 따른다. 얼마나 따를지는 학습된 가중치의 성질이므로, 같은 스케치를 더 느슨하게 반영하고 싶은 작가는 다른 체크포인트를 고르거나 가진 것이 학습된 대로 받아들여야 한다.

우리는 모델이 얼마나 귀 기울이는지가 아니라 조건 자체를 바꾼다. 조건은 정규화된 차단 반경 r 의 방사형 고주파 통과 필터를 거친 이미지다. $r=0$ 에서 모델은 회색조 이미지를 받고 과제는 색복원이 된다. r 이 커질수록 필터가 스펙트럼을 더 많이 제거해 $r=1$ 에서는 거의 남지 않는다. FFHQ에서 실측하면 차단 반경 0.05만 되어도 스펙트럼 에너지의 97.5%가 사라진다. 학습은 r 을 샘플마다 뽑으므로 가중치 하나가 전 구간을 보고, r 은 추론 시 파라미터가 된다. 기여는 다음과 같다.

- 제어 다이얼. 어댑터 하나가 $r \in [0.05, 0.3]$ 에서 구조 순응도 0.7469에서 0.2347까지를 담당하며 FID는 51.58와 54.68 사이다 (4.2절).
- 이 다이얼이 어댑터 세기를 다시 스케일한 것이

아니라는 근거. 가장 가까운 대응 쌍에서 두 설정은 구조 순응도 0.2146과 0.2347에, FID 76.46과 52.77에 도달한다 (4.3절).

- 고주파 조건이 동결 VAE를 얼마나 통과하는지에 대한 측정. 잠재 공간 조건화가 희소한 구조에서 실패하는 이유를 설명한다 (4.4절).
- 주입 위치가 어댑터 용량이나 수용 영역보다 중요함을 보이는 통계 비교 (4.5절).

2 관련 연구

조건부 제어. 텍스트-이미지 확산 모델 [6, 18, 26, 27, 29]은 ControlNet [34]으로 공간 제어가 가능해졌다. 인코더를 복제하고 0 합성곱으로 잔차를 주입하는 방식이다. T2I-Adapter [17]는 작은 특징 추출기로 같은 일을 하고, IP-Adapter [32]는 이미지 프롬프트를 위한 분리형 교차 어텐션을 더하며, GLIGEN [13]은 박스로 생성을 접지한다. Uni-ControlNet [37]과 Uni-Control [24]은 여러 조건 유형을 한 모델에 담고, ControlNet++ [12]는 생성된 이미지에서 일관성 루프를 단는다. 이들 모두 조건 유형을 고정하고, 그와 함께 출력이 얼마나 따를지도 고정한다. 동작점이 학습된 가중치의 성질이 되는 것이다. 우리의 차단 반경은 가중치 하나에서 추론 시 그 점을 옮긴다.

트랜스포머 백본에서의 효율적 제어. 백본이 UNet에서 확산 트랜스포머 [1, 20]로 옮겨가면서 제어도 복제 인코더에서 경량 모듈로 이동했다. ControlNeXt [21]는 병렬 분기를 없애고, OminiControl [30]은 백본 자체를 조건 처리기로 재사용하며, EasyControl [36]과 NanoControl [15]은 LoRA [7] 계열 모듈로 훨씬 적은 파라미터에서 조건을 주입한다. 조건이 어디로 들어가야 하는지도 최근 연구 대상이다. Laytrol [9]은 레이아웃 제어에서 사전학습 지식 보존을, PixelControl [14]은 조건 충실도를, Zhou et al. [38]은 다중 조건 DiT의 중복 어텐션 제거를 다룬다. 우리의 주입 위치 비교(4.5절)는 UNet 백본에서 양립하는 결론에 도달한다. 위치가 용량을 압도한다.

확산 모델에서의 주파수. 주파수 분해는 확산 연구에서 대개 조건이 아니라 모델 자신의 신호에 대한 개입으로 나타난다. FreeU [28]는 스킵과 백본 특징을 학습 없이 스펙트럼 상에서 재조정하고, FreSca [8]는 노이즈 예측의 주파수 대역을 스케일하며 우리처럼 에너지 기반 차단을 쓴다. DeCo [16]는 픽셀 공간 확산에서 주파수를 분리하고, FeRA [33]는 주파수 에너지로 적응을 라우팅한다. FOCUS [31]는 테스트 시 적응을 위해 학습된 주파수 사전으로 역과정을 조건화한다. 취지상 가장 가까운 것은 Prasain [23]로, 지도-위성 합성에서 엣지 맵 대신 웨이블릿 대역으로 조건화한다. 그러나 어느 연구도 학습 중 조건의

대역폭을 무작위화해 그 대역이 추론 시 제어가 되게 하지는 않으며, 그것이 우리가 다루는 기제다.

구조 보존. StructDiff [3]는 구조 보존형 공간 제어 생성을 목표로 하고, 스케치 조건 파이프라인은 오래전부터 엣지 맵을 구조 전달자로 써 왔다. 주파수 대역 자체가 편집 축이라는 착상과, 그림이 경성 제약이 아니라 연성 제약으로 작동해야 한다는 관점은 둘 다 확산 모델 이전의 그래픽스 문헌에 있다. 우리의 동기 문장이 그 계보에서 빌려왔으나 아래 참고문헌은 아직 그것을 반영하지 않는다. 우리 조건은 고정된 추출기가 아니라 연속체이며, 그것이 다이얼을 가능하게 한다.

학습과 평가. 분류자 없는 유도 [5] 드롭아웃과 Min-SNR 손실 가중 [2]으로 학습하고, FID [4]를 clean-FID 프로토콜 [19]로, LPIPS [35]와 CLIP 점수 [25]를 BLIP [11] 캡션이 달린 FFHQ [10]에서 평가한다. SDXL과 SD3 [1, 22]가 다음 백본으로 자연스럽다.

3 방법

조건. 이미지 x 를 회색조로 바꾸고 2차원 FFT를 취한 뒤 반지름 $r \cdot \min(H, W)/2$ 원판 안의 모든 주파수를 0으로 만들고 역변환한 다음 $[0, 1]$ 로 최소-최대 정규화한다. 정규화는 의도적이다. 필터 응답의 절대 크기를 없애 모델이 공간 통계만으로 구조 밀도를 추론하게 만든다. r 을 갖지 않는 손그림을 추론 시 쓸 수 있는 이유가 여기에 있다고 가정한다. 정규화 자체는 어블레이션하지 않았다. 그림 1는 마스크와 마스크된 스펙트럼, 그리고 그 결과 조건을 전 구간에 걸쳐 나란히 보여준다.

조건 인코더. 스트라이드 합성곱 스템이 512^2 조건 이미지를 직접 읽어 $8 \times$ 줄인다. 조건을 동결 VAE로 인코딩하지 않는다. 이유는 4.4절에 있다.

주입. 인코더 특징은 UNet에 두 곳으로 들어간다. 0으로 초기화된 1×1 헤드가 디코더 스킵 텐서마다 잔차 하나와 중간 블록용 잔차 하나를 만들어 UNet의 기존 ControlNet 인터페이스로 더한다. 동시에 각 교차 어텐션 지점이 조건 특징의 3×3 창을 참조하며, 0으로 초기화된 채널별 게이트를 거친다. 두 경로 모두 초기에는 정확한 무연산이다. 둘을 끄면 네트워크가 원본 Stable Diffusion 1.5 [26]를 비트 단위로 재현하며, 모든 학습 전에 이를 검사한다.

학습. SD1.5 [26]는 동결한다. BLIP [11] 캡션이 달린 FFHQ-512 [10]에서 6,611,469개 파라미터를 학습한다. 70,000장을 시드 2026으로 섞어 학습 65,100 / 검증 1,400 / 테스트 3,500로 나눈다(테스트 5%, 검증 2%). AdamW, 학습률 10^{-4} , $\beta = (0.9, 0.999)$, 500스텝 워밍업의 코사인 스케줄, 기울기 클리핑 1.0, 배치 32, bf16, H200 한 장에서 12에폭. 손실은 ϵ 예측에 Min-SNR 가중 [2] $\gamma = 5$ 를 적용한다. 텍스트 조건은 확률 0.1로, 구조 조건은 독립적으로 확률 0.05로 드롭한다. 어댑터의 EMA를 10스텝 간격으로 유지한다. r 은 샘플마다 $[0, 1]$ 균등분포에서 뽑는다. 코드와 어댑터 가중치를 함께 제출한다.

4 실험

4.1 지표

보유한 3,500장 중 500장에서 DDIM 샘플러 50스텝, CFG 7.5, 시드 2026으로 평가한다.

구조 순응도. SC는 생성 이미지를 회색조로 바꾸고, 모델에 준 것과 같은 차단 반경으로 같은 고주파 필터를 적용한 뒤, 주어진 조건과의 Pearson 상관을 편 픽셀 벡터에 대해 이미지별로 계산해 평균한다. 두 신호 모두 이미지별 최소-최대 정규화된 필터 출력이므로 상관은 스케일에 무관하다. 두 앵커가 범위를 묶는다. 정답 이미지를 그대로 넣으면 모든 r 에서 정확히 1.000이고, 무관한 얼굴은 $r=0$ 에서 0.122, 그 위에서는 ≈ -0.02 다. 자가 r 에 따라 움직이므로 행 간 차이는 모델 거동과 측정도구 변화의 합이다. 그래서 차단 반경과 무관한 지표를 함께 싣는다.

Edge-F1. 8비트 회색조 이미지에서 Canny 엣지(임계 100, 200)를 생성물과 참조 양쪽에서 추출하고, 각 맵을 5×5 로 팽창시켜 교차하는 방식으로 2픽셀 허용 오차를 두어 대응시킨다. F1을 이미지별로 계산해 평균한다. r 에 의존하지 않으며 그래서 표 1에 싣는다. $r=0.05$ 에서 0.7796, $r=1$ 에서 0.4724로, 차단 반경과 무관한 자료 재도 다이얼이 살아 있고, 정렬된 FFHQ 얼굴이 공짜로 주는 바닥이 0.4724 근처다.

다양성. 하나의 조건에서 시드를 바꿔 생성한 $K=4$ 개 표본에 대한 평균 쌍별 LPIPS(AlexNet)다. 높을수록 조건이 덜 구속한다. LPIPS 열과 독립이 아니다. 전 구간에서 LPIPS - 다양성이 0.0320 ± 0.0038 로 범위 0.20에 걸쳐 거의 상수이므로, 두 열이 사실상 같은 정보를 담는다고 보고 다양성만으로 별도 결론을 내지 않는다.

FID와 CLIP. 생성 500장과 같은 참조 500장 사이의 clean-FID [4, 19], 그리고 각 이미지 자신의 캡션에 대한 ViT-B/32 [25] CLIP 점수다.

4.2 다이얼

표 1이 동작 곡선이다. $r \in [0.05, 0.3]$ 에서 구조 순응도는 매 단계 감소하고 표본 다양성은 매 단계 증가한다. 다이얼이 드러내야 할 균형이다. 다만 두 가지를 함께 적어야 한다. $r=0$ 에서 $r=0.05$ 로 갈 때 구조 순응도는 0.0479만큼 상승하며($z = 6.24$, 한 체크포인트 안의 대응 비교) 스위치는 왼쪽 끝에서 단조가 아니다. 같은 상승이 Edge-F1에서도 나타나므로($0.7776 \rightarrow 0.7796$) 지표 탓이 아니라 모델 거동이다. 오른쪽 끝에서는 $r=0.5$ 와 $r=0.7$ 이 시드 간에 구별되지 않는다(대응 $t = 0.732$, $df = 2$, 임계 4.303). FID는 전 구간에서 50.13과 57.40 사이에 머무르므로, 구간이 끝까지 쓸 만하게 유지되고 잡음으로 무너지지 않는다.

그림 3은 시드와 캡션을 고정하고 r 만 바꾼 것이다. 그림 4는 곡선과, 그 아래에 두 다이얼을 같은 구조 순응도/FID 평면에 함께 놓은 것이다.




Figure 1: 주파수 쪽에서 본 다이얼. 열은 $r = 0, 0.05, 0.1, 0.2, 0.3, 0.5, 0.7, 1.0$ 이다. **1행:** 방사형 마스크, 검은 부분이 제거된다. **2행:** 마스크 후 로그 크기 스펙트럼으로, 구멍이 바깥으로 커진다. **3행:** 모델이 실제로 받는 조건. **4행:** 같은 데이터를 $\pm 2\sigma$ 로 표시해 남아 있는 내용을 드러낸 것. $r \approx 0.2$ 위에서 조건은 평평한 회색으로 보이고 표준편차도 $r=0$ 의 0.196에서 $r=1$ 의 0.041로 떨어지지만, 4행에는 얼굴 윤곽이 남아 있고 모델은 $r=0.2$ 에서 SC 0.4019에 도달한다. 낮은 대비가 정보 없음을 뜻하지 않으며, 이미지별 정규화가 모델에 그것을 학습하도록 강제한다.

r	SC $\pm$ SEM	시드 sd	Edge-F1	다양성	FID
0.00	0.6991 $\pm$ 0.0070	0.0105	0.7776	0.2994	50.13
0.05	0.7469 $\pm$ 0.0030	0.0015	0.7796	0.3126	51.58
0.10	0.6211 $\pm$ 0.0035	0.0059	0.7439	0.3414	54.68
0.20	0.4019 $\pm$ 0.0037	0.0098	0.7113	0.3719	53.45
0.30	0.2347 $\pm$ 0.0041	0.0106	0.6878	0.3794	52.77
우리가 주장하는 구간 밖					
0.50	0.1259 $\pm$ 0.0047	0.0093	0.6225	0.4100	53.97
0.70	0.1110 $\pm$ 0.0047	0.0186	0.5788	0.4334	53.69
1.00	0.0010 $\pm$ 0.0006	0.0002	0.4724	0.5066	57.40

Table 1: 동작 곡선. 테스트 3,500장 중 500장. SEM은 그 500장에 대한 값이고, 시드 sd는 학습 시드 3개에 대한 값이다. Edge-F1은 같은 실행을 차단 반경과 무관한 자료 읽은 것이며, SC가 모델에 준 것과 같은 차단 반경으로 재추출하기 때문에 함께 실행한다(4.1절). FID는 간단히 추정값이 하나뿐이고 분산이 없으므로 행 간 비교에만 쓴다.

시드 2026, 2027, 2028에서 곡선은 안정적이다. $r=0.05$ 의 SC는 0.7479 ± 0.0015 , $r=0.3$ 은 0.2318 ± 0.0106 다.

4.3 세기는 같은 손잡이가 아니다

당연한 대안은 하나의 차단 반경으로 학습하고 추론 시 어댑터 기여를 스케일하는 것이다. 같은 체크포인트에서 $r=0.1$ 을 고정하고 두 주입 경로를 함께 스케일해 시험했다.

어댑터를 약하게 하면 이미지가 나빠지고, 조건의 대역폭을 좁히면 그렇지 않다. 주파수 파라미터화가 이 균형을 이동 가능하게 만든다.

설정	SC	다양성	FID
세기 0.25	0.0408	0.7752	104.95
세기 0.50	0.2146	0.6061	76.46
세기 0.75	0.4893	0.4171	58.90
$r=0.3$ (우리)	0.2347	0.3794	52.77
$r=0.5$ (우리)	0.1259	0.4100	53.97

Table 2: 세기 다이얼과 주파수 다이얼. 같은 SC에서 읽으면 세기 0.50은 0.2146을 FID 76.46에 도달하고, $r=0.3$ 은 0.2347을 FID 52.77에 도달한다.

4.4 VAE가 조건을 먹는다

조건을 동결 SD VAE로 인코딩하면 대부분을 잃는다. IP-Adapter [32] 같은 이미지 프롬프트 설계는 CLIP 이미지 인코더와 투영이라는 다른 경로를 쓰므로, 이 측정에는 그것에 대해 말하지 않는다. 그림 5가 이를 보여준다. 조건을 인코딩-디코딩 왕복시킨 뒤 다시 재면 $r=0.1$ 에서 0.8562, $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700가 남는다. 왕복은 잠재가 보존하는 양의 하한이다. 잠재에는 남아 있으나 동결 디코더가 복원하지 못하는 성분이 있을 수 있다. 다만 그 잠재를 읽는 어댑터는 왕복에서 잃은 것을 복구할 수 없다. 조건을 256에서 만들어 업샘플하면 구조가 더 낮은 절대 주파수로 옮겨가 훨씬 많이 보존되는데 ($r=0.3$ 에서 0.7978), 이는 예전 설정과 비교할 때 알아둘 만한 데이터 파이프라인 인공물이다.

4.5 어디에 주입할 것인가

같은 인코더와 학습 일정에서 시작해 한 번에 한 필드씩 바꿨다(표 3). 스킵 연결 잔차가 지배적이다. 그림 6가

Figure 3 illustrates the architecture of the proposed VAE-based model. The process begins with an input image x , which is converted to grayscale and then processed by FFT. The resulting latent variable r is used in the VAE decoder. The decoder consists of three stages (64, 32, 16) with skip connections from the encoder. The final output is a reconstructed image. The model is trained using a CLIP text encoder and a 16-point SA module, which outputs a signal of 0.2112 (b).

```

graph TD
    A[조건] --> B[↓ 해당 해상도로]
    B --> C["W_K, W_V (1×1)"]
    C --> D[unfold 3×3]
    D -- "위치마다  
이웃 9개" --> E["softmax(QK^T / √d) V"]
    E -- "L이 아니라 9개에  
대해" --> F["W_O (동결)"]
    F --> G["0초기화 게이트"]
    G -- "채널별" --> H[latent에도, 층 출력에도 디해짐]
    I[UNet latent] --> J["W_Q (동결)"]
    J --> E
  
```

조건 인코더 주입		SC $r=0.05$	SC $r=0.1$	FID $r=0.1$
어댑터 없음 (대조군)		0.0368	0.0082	120.50
동결 VAE	attn, 게이트 없음	0.0234	0.0147	76.25
동결 VAE	attn	0.0303	0.0177	65.71
conv	attn	0.1485	0.0772	56.39
conv, 128	attn	0.2826	0.1882	53.17
conv, 256	attn	0.2986	0.2158	52.84
conv	attn, 7×7	0.0359	0.0218	58.51
conv	attn + skip	0.7469	0.6211	54.68

용량은 훨씬 덜 기여한다. 투영을 128채널 스텝으로 넓히면 $r=0.05$ 의 SC가 0.1485에서 0.2826로 오르고, 다시 256으로 두 배 늘려도 0.2986에 그친다. 7×7 어텐션 차는 3×3 보다 나쁘다 (0.0359).

따라서 모델 하나가 넷을 압도하지는 않는다. 대신 특화 모델이 줄 수 없는 것을 준다. $r=0.1$ 로 학습한 모델은 $r=0.3$ 을 본 적이 없으므로 그 곡선은 점 하나다.



Figure 3: 시드와 캡션을 고정하고 r 만 바꾼 결과. 왼쪽부터 참조 이미지, $r = 0, 0.05, 0.1, 0.3, 0.5, 0.7, 1.0$. 배경의 인파가 벌어지고 안경테가 참조에서 멀어지며 옷 색이 분리되는 반면 신원과 자세는 남는다. 참조 이미지는 모델에 주어지지 않는다.




Figure 4: 위: 차단 반경이 커질수록 구조 순응도는 내려가고 표본 다양성은 올라간다. 아래: 같은 실행들을 구조 순응도/FID 평면에 놓은 것. 조건의 대역폭을 좁히면 FID가 거의 일정한 채로 축을 이동하고, 어댑터를 약하게 하면 같은 구조 순응도를 이미지 품질로 지불한다. 두 패널 모두 평가 출력에서 직접 그렸다.

4.8 손으로 그린 스케치

그림 7이 전이 결과다. 학습에 쓰인 적 없는 실제 얼굴 그림 40장에서, 입력 그림에 대한 구조 순응도는 0.5484, CLIP 점수는 23.43이다. FID는 보고하지 않는다. 40장은 안정적인 추정에 부족하고, 평가기가 값을 내는 대신 거부한다. 학습 도메인에서 크게 벗어난 일반 장면 그림 500장도 돌렸다. 구조 순응도는 0.1714로 떨어지고 FFHQ 대비 FID는 285.91다. 모델이 그림은 따르지만 얼굴을 만들지 못한다. 얼굴 모델에서 예상되는 실패이며 생략하지 않고 보고한다.




Figure 5: 오토인코더에 넣은 조건과, 인코딩-디코딩 왕복 후 다시 추출한 조건 사이의 상관, 24장. $r \approx 0.5$ 위에서는 조건이 사실상 사라지므로 VAE 잠재를 읽는 어댑터는 이를 복구할 수 없다. 조건을 256에서 만들어 확대하면 구조가 더 낮은 절대 주파수에 놓여 훨씬 많이 보존되며, 예전 파이프라인과 비교할 때 소스 해상도를 명시해야 하는 이유다.

5 한계

쓸 만한 구간은 대략 $r \in [0, 0.3]$ 이다. 그 위에서는 조건에 남은 에너지가 적어 $r=0.5$ 에서 스펙트럼의 0.0014 — 구조 순응도를 해석하기 어려워진다. 거의 비어 있는 두 신호는 모델이 무엇을 하든 상관없이 0에 가깝기 때문이다.

여기 있는 모든 것은 한 도메인(FFHQ 얼굴)과 한 백분(SD1.5)이다. 현재의 구조 제어 연구는 DiT 백분 [1, 20]으로 옮겨갔고, 거기서 LoRA [7] 계열 어댑터 [15, 30, 36]는 우리보다 훨씬 적은 파라미터로 제어를 보고한다. 우리 효율 수치는 ControlNet 대비로 읽어야 하며 그 연구선과 비교할 것이 아니다.

특화 모델 비교는 정직하지만 $r=0.1$ 에서 불리하고, 사용자 연구는 수행하지 않았다.

6 결론

학습 중 구조 조건의 대역폭을 무작위화하면 차단 반경이 추론 시 제어가 되고, 그 제어는 어댑터를 약하게 만드는 것으로 재현되지 않는다. 여기에




Figure 6: 두 주입 경로를 모두 켜는 경우, 각각 단독, 그리고 둘 다 끈 경우. skip 잔차가 구조 신호의 대부분을 나르고, 교차 어텐션 단독으로는 거의 회복하지 못하며, 둘 다 끄면 동결 백본으로 떨어진다(FID 120.50, 양쪽 켜었을 때는 50.13). 두 경로는 거의 가산적이다.



Figure 7: 손으로 그린 얼굴 스케치(홀수 열)와 모델이 만든 결과(짝수 열), 제로샷. 그림에는 차단 반경이 없으므로 모델이 그림 자체에서 구조 밀도를 읽어와야 하며, 이미지별 최소-최대 정규화가 이를 가능하게 한다. 스캔 대부분은 상단에 보관용 파일명이 적혀 있고 모델은 그것까지 다시 그린다. 주어진 조건을 문자 그대로 따르는 것이다. 그 띠를 넉넉히 덮도록 프레임 상단 20%(102행)를 통째로 제외하면 점수는 0.5398이 된다(-0.0086, 표준오차 0.32배). 즉 점수가 재는 것은 그 띠가 아니다.

도달하려면 조건이 네트워크에 들어가는 위치를 고치고 조건을 동결 오토인코더 밖에 두어야 했다. 두 발견은 SD1.5의 오토인코더와 UNet에서 측정된 것이며, 같은 계열 위의 조건화 설계에는 옮겨가리라 본다. 다른 계열은 시험하지 않았다.

References

- [1] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling rectified flow transformers for high-resolution image synthesis. *arXiv:2403.03206*, 2024. URL <https://arxiv.org/abs/2403.03206>.
- [2] Tiankai Hang, Shuyang Gu, Chen Li, Jianmin Bao, Dong Chen, Han Hu, Xin Geng, and Baining Guo. Efficient diffusion training via min-snr weighting strategy. *arXiv:2303.09556*, 2023. URL <https://arxiv.org/abs/2303.09556>.
- [3] Yinxi He, Kang Liao, Chunyu Lin, Tianyi Wei, and Yao Zhao. Structdiff: A structure-preserving and spatially controllable diffusion model for single-image generation. *arXiv:2604.12575*, 2026. URL <https://arxiv.org/abs/2604.12575>.
- [4] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. Gans trained by a two time-scale update rule converge to a local nash equilibrium. *arXiv:1706.08500*, 2017. URL <https://arxiv.org/abs/1706.08500>.
- [5] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv:2207.12598*, 2022. URL <https://arxiv.org/abs/2207.12598>.
- [6] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *arXiv:2006.11239*, 2020. URL <https://arxiv.org/abs/2006.11239>.
- [7] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv:2106.09685*, 2021. URL <https://arxiv.org/abs/2106.09685>.
- [8] Chao Huang, Susan Liang, Yunlong Tang, Jing Bi, Li Ma, Yapeng Tian, and Chenliang Xu. Fresca: Scaling in frequency space enhances diffusion models. *arXiv:2504.02154*, 2025. URL <https://arxiv.org/abs/2504.02154>.
- [9] Sida Huang, Siqi Huang, Ping Luo, and Hongyuan Zhang. Laytrol: Preserving pretrained knowledge in layout control for multimodal diffusion transformers. *arXiv:2511.07934*, 2025. URL <https://arxiv.org/abs/2511.07934>.
- [10] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. *arXiv:1812.04948*, 2018. URL <https://arxiv.org/abs/1812.04948>.
- [11] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. *arXiv:2201.12086*, 2022. URL <https://arxiv.org/abs/2201.12086>.
- [12] Ming Li, Taojiannan Yang, Huafeng Kuang, Jie Wu, Zhaoning Wang, Xuefeng Xiao, and Chen Chen. Controlnet++: Improving conditional controls with efficient consistency feedback. *arXiv:2404.07987*, 2024. URL <https://arxiv.org/abs/2404.07987>.
- [13] Yuheng Li, Haotian Liu, Qingyang Wu, Fangzhou Mu, Jianwei Yang, Jianfeng Gao, Chunyuan Li, and Yong Jae Lee. Gligen: Open-set grounded text-to-image generation. *arXiv:2301.07093*, 2023. URL <https://arxiv.org/abs/2301.07093>.
- [14] Xin Lin, Haodong Li, Zhifei Zhang, Yutong Yang, Haitian Zheng, Juanxi Tian, Zhe Lin, and Truong Nguyen. Pixelcontrol: Fine-grained condition fidelity in text-to-image diffusion. *arXiv:2608.15705*, 2026. URL <https://arxiv.org/abs/2608.15705>.
- [15] Shanyuan Liu, Jian Zhu, Junda Lu, Yue Gong, Li-uzhuozheng Li, Bo Cheng, Yuhang Ma, Liebuchu Wu, Xiaoyu Wu, Dawei Leng, and Yuhui Yin.

- Nanocontrol: A lightweight framework for precise and efficient control in diffusion transformer. *arXiv:2508.10424*, 2025. URL <https://arxiv.org/abs/2508.10424>.
- [16] Zehong Ma, Longhui Wei, Shuai Wang, Shiliang Zhang, and Qi Tian. Deco: Frequency-decoupled pixel diffusion for end-to-end image generation. *arXiv:2511.19365*, 2025. URL <https://arxiv.org/abs/2511.19365>.
- [17] Chong Mou, Xintao Wang, Liangbin Xie, Yanze Wu, Jian Zhang, Zhongang Qi, Ying Shan, and Xiaohu Qie. T2i-adapter: Learning adapters to dig out more controllable ability for text-to-image diffusion models. *arXiv:2302.08453*, 2023. URL <https://arxiv.org/abs/2302.08453>.
- [18] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever, and Mark Chen. Glide: Towards photorealistic image generation and editing with text-guided diffusion models. *arXiv:2112.10741*, 2021. URL <https://arxiv.org/abs/2112.10741>.
- [19] Gaurav Parmar, Richard Zhang, and Jun-Yan Zhu. On aliased resizing and surprising subtleties in gan evaluation. *arXiv:2104.11222*, 2021. URL <https://arxiv.org/abs/2104.11222>.
- [20] William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv:2212.09748*, 2022. URL <https://arxiv.org/abs/2212.09748>.
- [21] Bohao Peng, Jian Wang, Yuechen Zhang, Wenbo Li, Ming-Chang Yang, and Jiaya Jia. Controlnext: Powerful and efficient control for image and video generation. *arXiv:2408.06070*, 2024. URL <https://arxiv.org/abs/2408.06070>.
- [22] Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. Sdxl: Improving latent diffusion models for high-resolution image synthesis. *arXiv:2307.01952*, 2023. URL <https://arxiv.org/abs/2307.01952>.
- [23] Arisha Prasain. Beyond edge maps: Wavelet-domain conditioning for multi-adapter map-to-satellite diffusion. *arXiv:2608.00083*, 2026. URL <https://arxiv.org/abs/2608.00083>.
- [24] Can Qin, Shu Zhang, Ning Yu, Yihao Feng, Xinyi Yang, Yingbo Zhou, Huan Wang, Juan Carlos Niebles, Caiming Xiong, Silvio Savarese, Stefano Ermon, Yun Fu, and Ran Xu. Unicontrol: A unified diffusion model for controllable visual generation in the wild. *arXiv:2305.11147*, 2023. URL <https://arxiv.org/abs/2305.11147>.
- [25] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. *arXiv:2103.00020*, 2021. URL <https://arxiv.org/abs/2103.00020>.
- [26] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. *arXiv:2112.10752*, 2021. URL <https://arxiv.org/abs/2112.10752>.
- [27] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S. Sara Mahdavi, Rapha Gontijo Lopes, Tim Salimans, Jonathan Ho, David J Fleet, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. *arXiv:2205.11487*, 2022. URL <https://arxiv.org/abs/2205.11487>.
- [28] Chenyang Si, Ziqi Huang, Yuming Jiang, and Ziwei Liu. Freeu: Free lunch in diffusion u-net. *arXiv:2309.11497*, 2023. URL <https://arxiv.org/abs/2309.11497>.
- [29] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv:2010.02502*, 2020. URL <https://arxiv.org/abs/2010.02502>.
- [30] Zhenxiong Tan, Songhua Liu, Xingyi Yang, Qiaochu Xue, and Xinchao Wang. Ominicontrol: Minimal and universal control for diffusion transformer. *arXiv:2411.15098*, 2024. URL <https://arxiv.org/abs/2411.15098>.
- [31] Gabriel Tjio, Jie Zhang, Xulei Yang, Yun Xing, Nhat Chung, Xiaofeng Cao, Ivor W. Tsang, Chee Keong Kwoh, and Qing Guo. Focus: Frequency-optimized conditioning of diffusion models for mitigating catastrophic forgetting during test-time adaptation. *arXiv:2508.14437*, 2025. URL <https://arxiv.org/abs/2508.14437>.
- [32] Hu Ye, Jun Zhang, Sibao Liu, Xiao Han, and Wei Yang. Ip-adapter: Text compatible image prompt adapter for text-to-image diffusion models. *arXiv:2308.06721*, 2023. URL <https://arxiv.org/abs/2308.06721>.
- [33] Bo Yin, Xiaobin Hu, Xingyu Zhou, Yu He, Peng-Tao Jiang, Yue Liao, Junwei Zhu, Jiangning Zhang, Ying Tai, and Shuicheng Yan. Fera: Frequency-energy constrained routing for effective diffusion adaptation fine-tuning. *arXiv:2511.17979*, 2025. URL <https://arxiv.org/abs/2511.17979>.
- [34] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. *arXiv:2302.05543*, 2023. URL <https://arxiv.org/abs/2302.05543>.

- [35] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. *arXiv:1801.03924*, 2018. URL <https://arxiv.org/abs/1801.03924>.
- [36] Yuxuan Zhang, Yirui Yuan, Yiren Song, Haofan Wang, and Jiaming Liu. Easycontrol: Adding efficient and flexible control for diffusion transformer. *arXiv:2503.07027*, 2025. URL <https://arxiv.org/abs/2503.07027>.
- [37] Shihao Zhao, Dongdong Chen, Yen-Chun Chen, Jianmin Bao, Shaozhe Hao, Lu Yuan, and Kwan-Yee K. Wong. Uni-controlnet: All-in-one control to text-to-image diffusion models. *arXiv:2305.16322*, 2023. URL <https://arxiv.org/abs/2305.16322>.
- [38] Chao Zhou, Tianyi Wei, Yiling Chen, Wenbo Zhou, and Nenghai Yu. Rethinking multi-condition dits: Eliminating redundant attention via position-alignment and keyword-scoping. *arXiv:2602.06850*, 2026. URL <https://arxiv.org/abs/2602.06850>.