

구조 조건부 확산 모델을 위한 주파수 다이얼

익명 제출

Abstract

구조 조건부 확산 어댑터는 하나의 동작점에서 학습된다. Canny 엣지, 깊이 맵, 스케치 — 각각은 출력이 조건을 얼마나 따를지를 고정하고, 그 균형을 옮기려면 다시 학습해야 한다. 우리는 조건의 정보량을 무작위화해 어댑터 하나를 학습한다. 차단 반경 r 을 샘플마다 뽑는 고주파 통과 필터를 쓰고, 추론 시 r 을 다이얼로 되읽는다. FFHQ-512에서 구조 순응도는 $r=0.05$ 의 0.7469에서 $r=0.3$ 의 0.2347까지 내려가고 표본 다양성은 0.3126에서 0.3794까지 올라가며, FID는 그 구간에서 51.58와 54.68 사이에 머문다. 스위치는 $r=1$ 까지 보고하되 다이얼은 $r \in [0, 0.3]$ 에서만 주장한다. 그 위에서는 조건에 남은 에너지가 적어 구조 순응도를 해석할 수 없다. 어댑터 세기는 같은 손잡이가 아니다. 구조 순응도를 맞추면 — 세기 설정은 FID 0.2146, 차단 반경 $r=0.3$ 이 0.2347 — 세기 설정은 FID 76.46을 쓰고 차단 반경은 52.77를 쓴다. 차단 반경이 두 축에서 동시에 우위다. 작가가 손그림을 r 로 걸러 넣으면 다이얼은 손그림에서도 작동한다.

구현 과정에서 두 가지를 발견했다. 동결 SD VAE는 어댑터가 읽기 전에 고주파 조건을 과파한다. 인코딩-디코딩 왕복 후 남은 조건은 $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700에 불과하다. 그리고 이 두 주입 설계 사이에서는 위치가 폭보다 중요하다. skip 단독이 SC 0.5370를 유지하는 반면 어텐션 단독은 0.2112이고 양쪽 다 커면 0.6991다. 어텐션 단독 설계 안에서 어댑터 폭을 네 배로 늘려도 그보다 훨씬 적게 얻는다. 학습 파라미터는 6,611,469개다. ControlNet보다는 작지만 최근의 경량 제어 모듈보다 작지는 않으며, 효율을 기여로 주장하지 않는다.

1 서론

ControlNet [37]과 그 후속 연구들 [13, 18, 25, 40]은 조건부 제어를 풀고 그대로 굳혔다. Canny 엣지로 학습한 어댑터는 Canny 엣지를 따르고, 깊이로 학습한 어댑터는 깊이를 따른다. 얼마나 따를지는 학습된 가중치의 성질이므로, 같은 스케치를 더 느슨하게 반영하고 싶은 작가는 다른 체크포인트를 고르거나 가진 것이 학습된 대로 받아들여야 한다.

우리는 모델이 얼마나 귀 기울이는지가 아니라 조건 자체를 바꾼다. 조건은 정규화된 차단 반경 r 의 방사형 고주파 통과 필터를 거친 이미지다. $r=0$ 에서 모델은 회색조 이미지를 받고 과제는 색복원이 된다. r 이 커질수록 필터가 스펙트럼을 더 많이 제거해 $r=1$ 에서는 거의 남지 않는다. FFHQ에서 실측하면 차단 반경 0.05만 되어도 스펙트럼 에너지의 97.5%가 사라진다. 학습은 r 을 샘플마다 뽑으므로 가중치 하나가 전 구간을 보고, r 은 추론 시 파라미터가 된다.

기여는 다음과 같다.

- 제어 다이얼. 어댑터 하나가 $r \in [0.05, 0.3]$ 에서 구조 순응도 0.7469에서 0.2347까지를 담당하며

FID는 51.58와 54.68 사이다 (4.2절).

- 이 다이얼이 어댑터 세기를 다시 스케일한 것이 아니라는 근거. 가장 가까운 대응 쌍에서 두 설정은 구조 순응도 0.2146과 0.2347에, FID 76.46과 52.77에 도달한다 (4.3절).
- 고주파 조건이 동결 VAE를 얼마나 통과하는지에 대한 측정. 잠재 공간 조건화가 희소한 구조에서 실패하는 이유를 설명한다 (4.4절).
- 주입 위치가 어댑터 용량이나 수용 영역보다 중요함을 보이는 통제 비교 (4.5절).

2 관련 연구

조건부 제어. 텍스트-이미지 확산 모델 [7, 19, 27, 28, 30]은 ControlNet [37]으로 공간 제어가 가능해졌다. 인코더를 복제하고 0 합성곱으로 잔차를 주입하는 방식이다. T2I-Adapter [18]는 작은 특징 추출기로 같은 일을 하고, IP-Adapter [34]는 이미지 프롬프트를 위한 분리형 교차 어텐션을 더하며, GLIGEN [14]은 박스로 생성을 접지한다. Uni-ControlNet [40]과 UniControl [25]은 여러 조건 유형을 한 모델에 담고, ControlNet++ [13]는 생성된 이미지에서 일관성 루프를 닫는다. 같은 UNet에서 제어 분기를 줄이는 흐름도 있다. ControlNet-XS [36]는 훨씬 작은 제어 네트워크를 인코더·디코더와 양방향으로 연결하고, CtrLoRA [33]는 공유된 기반 ControlNet을 조건마다 LoRA로 적응시키며, Simple-ControlNet [2]은 UNet 최상단의 단일 스케일 투영과 self-attention의 LoRA만으로 300만 미만의 파라미터에서 조건을 넣고 추론 시 그 투영의 스케일을 조절하게 한다. 우리 어댑터는 이들보다 작지 않다. 이들 모두 조건 유형을 고정하고, 그와 함께 출력이 얼마나 따를지도 고정한다. 동작점이 학습된 가중치의 성질이 되는 것이다. 우리의 차단 반경은 가중치 하나에서 추론 시 그 점을 옮긴다.

트랜스포머 백본에서의 효율적 제어. 백본이 UNet에서 확산 트랜스포머 [1, 21]로 옮겨가면서 제어도 복제 인코더에서 경량 모듈로 이동했다. ControlNeXt [22]는 병렬 분기를 없애고, OminiControl [31]은 백본 자체를 조건 처리기로 재사용하며, EasyControl [39]과 NanoControl [16]은 LoRA [8] 계열 모듈로 훨씬 적은 파라미터에서 조건을 주입한다. 조건이 어디로 들어가야 하는지도 최근 연구 대상이다. Laytrol [10]은 레이아웃 제어에서 사전학습 지식 보존을, PixelControl [15]은 조건 충실도를, Zhou et al. [41]은 다중 조건 DiT의 중복 어텐션 제거를 다룬다. 우리의 주입 위치 비교(4.5절)는 UNet 백본에서 양립하는 결론에 도달한다. 위치가 용량을 압도한다.

확산 모델에서의 주파수. 주파수 분해는 확산 연구에서 대개 조건이 아니라 모델 자신의 신호에 대한

개입으로 나타난다. FreeU [29]는 스킵과 백본 특징을 학습 없이 스펙트럼 상에서 재조정하고, FreSca [9]는 노이즈 예측의 주파수 대역을 스케일하며 우리처럼 에너지 기반 차단을 쓴다. DeCo [17]는 픽셀 공간 확산에서 주파수를 분리하고, FeRA [35]는 주파수 에너지로 적응을 라우팅한다. FOCUS [32]는 테스트 시 적응을 위해 학습된 주파수 사전으로 역과정을 조건화한다. 취지상 가장 가까운 것은 Prasain [24]로, 지도-위성 합성에서 엣지 맵 대신 웨이블릿 대역으로 조건화한다. 그러나 어느 연구도 학습 중 조건의 대역폭을 무작위화해 그 대역이 추론 시 제어가 되게 하지는 않으며, 그것이 우리가 다루는 기제다.

구조 보존. StructDiff [4]는 구조 보존형 공간 제어 생성을 목표로 하고, 스케치 조건 파이프라인은 오래전부터 엣지 맵을 구조 전달자로 써 왔다. 주파수 대역 자체가 편집 축이라는 착상과, 그림이 경성 제약이 아니라 연성 제약으로 작동해야 한다는 관점은 둘 다 확산 모델 이전의 그래픽스 문헌에 있다. 우리의 동기 문장이 그 계보에서 빌려왔으나 아래 참고문헌은 아직 그것을 반영하지 않는다. 우리 조건은 고정된 추출기가 아니라 연속체이며, 그것이 다이얼을 가능하게 한다.

학습과 평가. 분류자 없는 유도 [6] 드롭아웃과 Min-SNR 손실 가중 [3]으로 학습하고, FID [5]를 clean-FID 프로토콜 [20]로, LPIPS [38]와 CLIP 점수 [26]를 BLIP [12] 캡션이 달린 FFHQ [11]에서 평가한다. SDXL과 SD3 [1, 23]가 다음 백본으로 자연스럽다.

3 방법

조건. 이미지 x 를 회색조로 바꾸고 2차원 FFT를 취한 뒤 반지름 $r \cdot \min(H, W)/2$ 원판 안의 모든 주파수를 0으로 만들고 역변환한 다음 $[0, 1]$ 로 최소-최대 정규화한다. 정규화는 의도적이다. 필터 응답의 절대 크기를 없애 모델이 공간 통계만으로 구조 밀도를 추론하게 만든다. r 을 갖지 않는 손그림을 추론 시 쓸 수 있는 이유가 여기에 있다고 가정한다. 정규화 자체는 어블레이션하지 않았다. 그림 1는 마스크와 마스크된 스펙트럼, 그리고 그 결과 조건을 전 구간에 걸쳐 나란히 보여준다.

조건 인코더. 스트라이드 합성곱 스템이 512^2 조건 이미지를 직접 읽어 $8 \times$ 줄인다. 조건을 동결 VAE로 인코딩하지 않는다. 이유는 4.4절에 있다.

주입. 인코더 특징은 UNet에 두 곳으로 들어간다. 0으로 초기화된 1×1 헤드가 디코더 스킵 텐서마다 잔차 하나와 중간 블록용 잔차 하나를 만들어 UNet의 기존 ControlNet 인터페이스로 더한다. 동시에 각 교차 어텐션 지점이 조건 특징의 3×3 창을 참조하며, 0으로 초기화된 채널별 게이트를 거친다. 효과를 내는 것은 창이 아니다. 1×1 에서는 softmax가 한 위치에 대해서만 계산되어 이 지점이 게이트 달린 값 투영으로 줄어드는데, 구조 순응도는 낮아지지 않는다(4.5절). 두 경로 모두 초기에는 정확한 무연산이다. 둘을 끄면 네트워크가 원본 Stable Diffusion 1.5 [27]를 비트 단위로 재현하며, 모든 학습 전에 이를 검사한다.

학습. SD1.5 [27]는 동결한다. BLIP [12] 캡션이 달린 FFHQ-512 [11]에서 6,611,469개 파라미터를 학습한다. 70,000장을 시드 2026으로 섞어 학습 65,100 / 검증 1,400 / 테스트 3,500로 나눈다(테스트 5%, 검증 2%). AdamW, 학습률 10^{-4} , $\beta = (0.9, 0.999)$, 500스텝 워밍업의 코사인 스케줄, 기울기 클리핑 1.0, 배치 32, bf16, H200 한 장에서 12에폭. 손실은 ϵ 예측에 Min-SNR 가중 [3] $\gamma = 5$ 를 적용한다. 텍스트 조건은 확률 0.1로, 구조 조건은 독립적으로 확률 0.05로 드롭한다. 어댑터의 EMA를 10스텝 간격으로 유지한다. r 은 샘플마다 $[0, 1]$ 균등분포에서 뽑는다. 코드와 어댑터 가중치를 함께 제출한다.

4 실험

4.1 지표

보류한 3,500장 중 500장에서 DDIM 샘플러 50스텝, CFG 7.5, 시드 2026으로 평가한다.

구조 순응도. SC는 생성 이미지를 회색조로 바꾸고, 모델에 준 것과 같은 차단 반경으로 같은 고주파 필터를 적용한 뒤, 주어진 조건과의 Pearson 상관을 편 픽셀 벡터에 대해 이미지별로 계산해 평균한다. 두 신호 모두 이미지별 최소-최대 정규화된 필터 출력이므로 상관은 스케일에 무관하다. 두 앵커가 범위를 묶는다. 정답 이미지를 그대로 넣으면 모든 r 에서 정확히 1.000이고, 무관한 얼굴은 $r=0$ 에서 0.122, 그 위에서는 ≈ -0.02 다. 자가 r 에 따라 움직이므로 행 간 차이는 모델 거동과 측정도구 변화의 합이다. 그래서 차단 반경과 무관한 지표를 함께 싣는다.

Edge-F1. 8비트 회색조 이미지에서 Canny 엣지(임계 100, 200)를 생성물과 참조 양쪽에서 추출하고, 각 맵을 5×5 로 팽창시켜 교차하는 방식으로 2픽셀 허용 오차를 두어 대응시킨다. F1을 이미지별로 계산해 평균한다. r 에 의존하지 않으며 그래서 표 1에 싣는다. $r=0.05$ 에서 0.7796, $r=1$ 에서 0.4724로, 차단 반경과 무관한 자로 재도 다이얼이 살아 있고, 정렬된 FFHQ 얼굴이 공짜로 주는 바닥이 0.4724 근처다.

다양성. 하나의 조건에서 시드를 바꿔 생성한 $K=4$ 개 표본에 대한 평균 쌍별 LPIPS(AlexNet)다. 높을수록 조건이 덜 구속한다. LPIPS 열과 독립이 아니다. 전 구간에서 LPIPS - 다양성이 0.0320 ± 0.0038 로 범위 0.20에 걸쳐 거의 상수이므로, 두 열이 사실상 같은 정보를 담는다고 보고 다양성만으로 별도 결론을 내지 않는다.

FID와 CLIP. 생성 500장과 같은 참조 500장 사이의 clean-FID [5, 20], 그리고 각 이미지 자신의 캡션에 대한 ViT-B/32 [26] CLIP 점수다.

4.2 다이얼

표 1이 동작 곡선이다. $r \in [0.05, 0.3]$ 에서 구조 순응도는 매 단계 감소하고 표본 다양성은 매 단계 증가한다. 다이얼이 드러내야 할 균형이다. 다만 두 가지를 함께 적어야 한다. $r=0$ 에서 $r=0.05$ 로




그림 1: 주파수 쪽에서 본 다이얼. 열은 $r = 0, 0.05, 0.1, 0.2, 0.3, 0.5, 0.7, 1.0$ 이다. 1행: 방사형 마스크, 검은 부분이 제거된다. 2행: 마스크링 후 로그 크기 스펙트럼으로, 구멍이 바깥으로 커진다. 3행: 모델이 실제로 받는 조건. 4행: 같은 데이터를 $\pm 2\sigma$ 로 표시해 남아있는 내용을 드러낸 것. $r \approx 0.2$ 위에서 조건은 평평한 회색으로 보이고 표준편차도 $r=0$ 의 0.196에서 $r=1$ 의 0.041로 떨어지지만, 4행에는 얼굴 윤곽이 남아 있고 모델은 $r=0.2$ 에서 SC 0.4019에 도달한다. 낮은 대비가 정보 없음을 뜻하지 않으며, 이미지별 정규화가 모델에 그것을 학습하도록 강제한다.

갈 때 구조 순응도는 0.0479만큼 상승하며($z = 6.24$, 한 체크포인트 안의 대응 비교) 스위치는 왼쪽 끝에서 단조가 아니다. 같은 상승이 Edge-F1에서도 나타나므로($0.7776 \rightarrow 0.7796$) 지표 탓이 아니라 모델 거동이다. 오른쪽 끝에서는 $r=0.5$ 와 $r=0.7$ 이 시드 간에 구별되지 않는다(대응 $t = 0.732$, $df = 2$, 임계 4.303). FID는 전 구간에서 50.13과 57.40 사이에 머무르므로, 구간이 끝까지 쓸 만하게 유지되고 잡음으로 무너지지 않는다.

그림 3은 시드와 캡션을 고정하고 r 만 바꾼 것이다. 캡션이 참조에서 유도되므로 구조의 일부를 캡션이 나르고 있을 수 있다. 그래서 모든 이미지에 일반 캡션 하나("a photo of a person")를 주고 스위치를 반복했다. 구조 순응도는 거의 움직이지 않는다. $r=0, 0.1, 0.3$ 에서 0.7039, 0.6179, 0.2196로, 캡션이 있을 때의 0.6991, 0.6211, 0.2347와 같은 수준이다. 반면 FID는 55.56–65.84로 오르는데, 캡션이 이미지를 설명하지 않게 되었으니 당연하다. 구조는 조건에서 온다. 그림 4는 곡선과, 그 아래에 두 다이얼을 같은 구조 순응도/FID 평면에 함께 놓은 것이다.

시드 2026, 2027, 2028에서 곡선은 안정적이다. $r=0.05$ 의 SC는 0.7479 ± 0.0015 , $r=0.3$ 은 0.2318 ± 0.0106 다.

4.3 세기는 같은 손잡이가 아니다

당연한 대안은 하나의 차단 반경으로 학습하고 추론 시 어댑터 기여를 줄이는 것으로, 경량 제어 모듈이 제공하는 손잡이이기도 하다 [2]. 고정 $r=0.1$ 로 학습한 어댑터(4.6절)에서 두 주입 경로를 함께 스케일해 이를 그대로 수행했고, 확인용으로 무작위- r 모델도 같은 차단 반경에서 스케일했다.

두 스케일 곡선 모두 줄일수록 이미지 분포를

r	SC $\pm$ SEM	시드 sd	Edge-F1	다양성	FID
0.00	0.6991 ± 0.0070	0.0105	0.7776	0.2994	50.13
0.05	0.7469 ± 0.0030	0.0015	0.7796	0.3126	51.58
0.10	0.6211 ± 0.0035	0.0059	0.7439	0.3414	54.68
0.20	0.4019 ± 0.0037	0.0098	0.7113	0.3719	53.45
0.30	0.2347 ± 0.0041	0.0106	0.6878	0.3794	52.77
우리가 주장하는 구간 밖					
0.50	0.1259 ± 0.0047	0.0093	0.6225	0.4100	53.97
0.70	0.1110 ± 0.0047	0.0186	0.5788	0.4334	53.69
1.00	0.0010 ± 0.0006	0.0002	0.4724	0.5066	57.40


표 1: 동작 곡선. 테스트 3,500장 중 500장. SEM은 그 500장에 대한 값이고, 시드 sd는 학습 시드 3개에 대한 값이다. Edge-F1은 같은 실행을 차단 반경과 무관한 자료 읽은 것이며, SC가 모델에 준 것과 같은 차단 반경으로 재추출하기 때문에 함께 실는다(4.1 절). FID는 칸마다 추정값이 하나뿐이고 분산이 없으므로 행 간 비교에만 쓴다.

벗어난다. 세기 0.25에서 고정- r 어댑터는 FID 102.43, 다양성 0.7689에 이르는데, 차단 반경은 전 구간에서 FID가 50.13–57.40에 머물고 다양성은 최대 0.5066다. 어댑터를 줄이면 표본을 망가뜨려 구조를 없애고, 조건의 대역을 좁히면 화질을 유지한 채 구조를 없앤다.

4.4 VAE가 조건을 먹는다

조건을 동결 SD VAE로 인코딩하면 대부분을 잃는다. IP-Adapter [34] 같은 이미지 프롬프트 설계는 CLIP 이미지 인코더와 투영이라는 다른 경로를 쓰므로, 이 측정은 그것에 대해 말하지 않는다. 그림 5가 이를 보여준다. 조건을 인코딩-디코딩 왕복시킨 뒤 다시 재면 $r=0.1$ 에서 0.8562, $r=0.3$ 에서 0.5773, $r=0.7$ 에서 0.0700가 남는다. 왕복은 잠재가 보존하는 양의

(a) 조건 경로와 두 주입 지점



(b) 한 지점의 내부




그림 2: (a) 반경 r 의 원판을 스펙트럼에서 제거하고, 학습되는 합성곱 인코더가 그 결과를 전체 해상도로 읽는다. VAE는 거치지 않는다. 그 특징은 동결 UNet에 두 번 들어간다. 모든 skip 텐서에 0으로 초기화된 잔차로($\oplus$), 그리고 교차 어텐션 16곳의 StandAlone 어텐션으로. 선 굵기는 측정된 분배를 따른다. skip 경로가 구조 신호의 0.5370를, 어텐션이 0.2112를 나른다(4.5절). (b) StandAlone 한 지점. 쿼리는 UNet 자신의 latent에서 동결 W_Q 를 거쳐 오고, 키와 값은 조건에서 학습된 1×1 투영을 거쳐 온다. unfold로 각 위치가 전체 맵이 아니라 자기 3×3 이웃만 참조한다. 결과는 동결 출력 투영과 0초기화 채널별 게이트를 지나, latent에 더해져 아래의 텍스트 쿼리가 구조를 보게 하고, 층이 반환하는 값에도 더해진다.




그림 3: 행마다 시드와 캡션을 하나로 고정하고 r 만 바꿨다. 행은 테스트 이미지의 처음 세 장을 생성 순서대로 실은 것이다. r 이 커질수록 배경의 세부가 멀어지고 옷과 색이 참조에서 멀어지지만 얼굴 배치는 유지된다. $r=1$ 에서는 둘째 행의 자세도 바뀐다. 참조 이미지는 모델에 주어지지 않는다.

하한이다. 잠재에는 남아 있으나 동결 디코더가 복원하지 못하는 성분이 있을 수 있다. 다만 그 잠재를 읽는 어댑터는 왕복에서 읽은 것을 복원할 수 없다. 조건을 256에서 만들어 업샘플하면 구조가 더 낮은 절대 주파수로 옮겨가 훨씬 많이 보존되는데 ($r=0.3$ 에서 0.7978), 이는 예전 설정과 비교할 때 알아둘 만한 데이터 파이프라인 인공물이다.

4.5 어디에 주입할 것인가

같은 인코더와 학습 일정에서 시작해 한번에 한 필드씩 바꿨다(표 4). 스킵 연결 잔차가 지배적이다. 그림 6가 이를 분해한다. 제거하고 교차 어텐션만 남기면 $r=0$ 의 SC가 0.6991에서 0.2112로 떨어지고, 스킵 경로만 남기면 0.5370가 유지된다. 두 경로를 모두 끄면 SC 0.0368, FID 120.50로 무너지는데, 이것이 어댑터가 일을 하고 있다는 대조군이다. 두 축에서 분배가

같지는 않다. SC에서는 skip 경로가 약 $2.5 \times$ 앞서지만 FID에서는 두 경로가 거의 구별되지 않는다(65.12 대 67.07). 우리가 측정한 위치 효과는 구조 충실도 효과이지 일반적인 화질 효과가 아니다.

용량은 훨씬 덜 기여한다. 투영을 128채널 스템으로 넓히면 $r=0.05$ 의 SC가 0.1485에서 0.2826로 오르고, 다시 256으로 두 배 늘려도 0.2986에 그친다. 7×7 어텐션 창은 3×3 보다 나쁘다 (0.0359). 이 행들은 모두 skip 경로 없이 용량을 바꾼 것이다.

표 3은 작동하는 설계에서 두 경로를 모두 켜 한 필드씩 바꾼 어블레이션이다. 각각 시드 하나이므로 주 모델의 시드 3개 퍼짐(SC 약 0.01)에 비추어 읽는다. 여기서도 용량은 조금 돕는다. 256채널 스템은 $r=0.05$ 의 SC를 0.7469에서 0.7631로 올리고 $r=0.1$ 의 FID를 54.68에서 51.36로 낮추지만, skip 경로를 더할 때($r=0$ 에서 0.2112 $\rightarrow$ 0.6991)에 비하면 작다. 어텐션 창은 돕지 않는다. 1×1 은 표의 모든 차단 반경에서




그림 4: 위: 차단 반경이 커질수록 구조 순응도는 내려가고 표본 다양성은 올라간다. 아래: 같은 실행들을 구조 순응도/FID 평면에 놓은 것. 조건의 내역폭을 좁히면 FID가 거의 일정한 채로 축을 이동하고, 어댑터를 약하게 하면 같은 구조 순응도를 이미지 품질로 지불한다. 두 패널 모두 평가 출력에서 직접 그렸다.




그림 5: 오토인코더에 넣은 조건과, 인코딩-디코딩 왕복 후 다시 추출한 조건 사이의 상관, 24장. $r \approx 0.5$ 위에서는 조건이 사실상 사라지므로 VAE 잠재를 읽는 어댑터는 이를 복구할 수 없다. 조건을 256에서 만들어 확대하면 구조가 더 낮은 절대 주파수에 놓여 훨씬 많이 보존되며, 예전 파이프라인과 비교할 때 소스 해상도를 명시해야 하는 이유다.

3×3 과 시드 퍼짐 안에서 같거나 더 높고, 5×5 는 모두 낮다. 어텐션 지점이 기여하는 것은 이웃이 아니라 조건이 들어가는 위치다. 0초기화 게이트는 유지할 가치가 있다. 없애면 $r=0$ 부터 0.3까지 SC가 낮고 $r=0.1$ 의 FID가 높다. 가장 큰 단일 변화는 r 를 뽑는 방식이다. 로그-균등 샘플러는 $r=0$ 의 SC를 0.9480로 올리고 FID를 42.06로 낮추지만 윗구간을 내준다($r=0.5$ 에서 0.0858 대 0.1259). 다이얼을 전 구간에서 개선한다기보다 해상도를 작은 r 쪽으로 옮기는 것이다. 위의 결과는 모두 균등 샘플러로 얻었다.

4.6 차단 반경별 특화 모델과의 비교

고정 r 로 어댑터 네 개를 학습해 각자의 차단 반경에서 무작위- r 모델 하나와 비교했다. 하나의 모델은 세 번 학습했으므로, 각 격차를 실행 내 표준오차가 아니라 시드 3개의 퍼짐에 대해 표시한다. $df = 2$ 의 양측 t 임계값(4.303)보다 작은 격차는 구별되지

설정	SC	다양성	FID
고정 $r=0.1$ 어댑터, 스케일			
세기 0.25	0.0640	0.7689	102.43
세기 0.50	0.3193	0.5540	70.91
세기 0.75	0.5829	0.4044	57.52
세기 1.00	0.7050	0.2967	48.51
무작위-r 어댑터, $r=0.1$에서 스케일			
세기 0.25	0.0408	0.7752	104.95
세기 0.50	0.2146	0.6061	76.46
세기 0.75	0.4893	0.4171	58.90
무작위-r 어댑터, 차단 반경 이동			
$r=0.2$	0.4019	0.3719	53.45
$r=0.3$	0.2347	0.3794	52.77

표 2: 세기와 차단 반경. 고정- r 어댑터는 세기 0.50에서 SC 0.3193, FID 70.91에 이른다. 차단 반경을 옮기면 $r=0.2$ (0.4019, FID 53.45)와 $r=0.3$ (0.2347, FID 52.77)이 그 값을 사이에 두며, 둘 다 FID가 낮다. 무작위 모델을 스케일해도 같은 양상이다.




그림 6: 두 주입 경로를 모두 켜 경우, 각각 단독, 그리고 둘 다 끈 경우. skip 잔차가 구조 신호의 대부분을 나르고, 교차 어텐션 단독으로는 거의 회복하지 못하며, 둘 다 끄면 동결 백본으로 떨어진다(FID 120.50, 양쪽 켜 있을 때는 50.13). 두 경로는 거의 가산적이다.

않는다. 결과는 엇갈린다. $r=0.1$ 에서는 특화 모델이 이기고(0.7049 대 0.6245, $\Delta = +0.0803$, +13.55 sd), $r=0.3$ 에서는 하나의 모델이 이긴다(0.2318 대 0.1214, -0.1104 , -10.42 sd). $r=0.5$ (-1.00 sd)와 $r=0.7$ (+0.14 sd)은 구별되지 않는다. 앞서 단일 시드로 읽었을 때 $r=0.7$ 을 특화 모델의 근소한 승리로 적었으나, 시드 간에는 무승부다.

따라서 모델 하나가 넷을 압도하지는 않는다. 대신 특화 모델이 줄 수 없는 것을 준다. $r=0.1$ 로 학습한 모델은 $r=0.3$ 을 본 적이 없으므로 그 곡선은 점 하나다.

4.7 베이스라인

같은 테스트 이미지와 캡션에서 사전학습 ControlNet [37]을 자기 조건으로 돌린 결과다. ControlNet-Canny는 Edge-F1 0.6854, LPIPS 0.5294, FID 71.92이고 학습 파라미터는 361,279,120개다. ControlNet-HED는 0.5733 / 0.6548 / 118.98다. $r=0.1$ 에서 우리 어댑터는 Edge-F1 0.7439, LPIPS 0.3748, FID 54.68를 6,611,469개 파라미터로 낸다. 두 가지 비대칭 때문에 이는 동일 조건 비교가 아니라 동작점 비교다. 조건이 다르고(Canny 엣지 대 주파수 대역), 우리 어댑터는 FFHQ 65,100장으로 학습한 반면 ControlNet은 여기서 제로샷이며 FID도 FFHQ 통계 대비다. 텍스트 정합에서는 어디서도 이기지 못한다. 전 구간 최고

바꾼 필드	SC				FID
	$r=0$	0.05	0.3	0.5	$r=0.1$
주 모델	0.6991	0.7469	0.2347	0.1259	54.68
시드 sd (3개)	0.0105	0.0015	0.0106	0.0093	-
창 1×1	0.7825	0.7640	0.2271	0.1255	55.70
창 5×5	0.6764	0.7175	0.2039	0.0944	55.68
게이트 없음	0.6838	0.7322	0.2058	0.1290	57.02
평균 풀링 축소	0.7203	0.7465	0.2279	0.1241	55.13
스텝 64	0.7775	0.7594	0.2354	0.1170	51.91
스텝 256	0.7900	0.7631	0.2511	0.1214	51.36
컬러 조건	0.6949	0.7463	0.2343	0.1255	54.75
조건 드롭아웃 없음	0.7042	0.7353	0.2279	0.1231	54.69
$r = u^2$	0.8936	0.7836	0.2468	0.1039	53.46
r 로그-균등	0.9480	0.8000	0.2302	0.0858	54.87

표 3: 작동하는 모델에서 한 필드씩 바꾼 어블레이션. skip과 어텐션 경로를 모두 켜고 각각 학습 시드 하나다. 둘째 행은 주 모델의 시드 3개에 대한 퍼짐이다. 주 모델은 3×3 창, 0초기화 게이트, 어텐션 지점마다 조건 특징을 학습형 2×2 스트라이드로 축소, 스텝 없음, 회색조 조건, 조건 드롭아웃 0.05, [0, 1] 균등 r 을 쓴다. u 를 균등하게 뽑아 $r = u^2$ 로 두면 작은 r 에 학습이 몰리고, $[10^{-3}, 1]$ 로그-균등 샘플러는 더 강하게 몰린다.

조건 인코더 주입		SC $r=0.05$	SC $r=0.1$	FID $r=0.1$
어댑터 없음 (대조군)		0.0368	0.0082	120.50
동결 VAE	attn, 게이트 없음	0.0234	0.0147	76.25
동결 VAE	attn	0.0303	0.0177	65.71
conv	attn	0.1485	0.0772	56.39
conv, 128	attn	0.2826	0.1882	53.17
conv, 256	attn	0.2986	0.2158	52.84
conv	attn, 7×7	0.0359	0.0218	58.51
conv	attn + skip	0.7469	0.6211	54.68

표 4: 누적 사슬이 아니라 절대 구성이다. 대조군 아래 각 행은 conv / attn 행과 정확히 한 필드가 다르며, 명시하지 않는 한 모두 3×3 창과 0초기화 게이트를 쓴다. 메인 모델은 마지막 행이고 스텝이 없다(최소 1×1 투영). 위 세 행은 어댑터 없음 대조군과 같거나 그 아래이므로, 그 수준에서는 설계가 나쁜 것과 학습이 되지 않은 것을 구별할 수 없다. skip 경로를 컨 상태의 스텝 폭 변화는 표 3에 있다.

CLIP이 30.30로 ControlNet-Canny의 30.34에 못 미친다 (ControlNet-HED는 29.16). 복제 인코더가 아니라 77,000,640개 파라미터의 걸가지 네트워크라 우리 설계에 더 가까운 T2I-Adapter-Canny [18]는 같은 프로토콜에서 Edge-F1 0.5845, LPIPS 0.5690, FID 86.66, CLIP 30.58이다. 스케치 체크포인트는 제외했다. PiDiNet 스케치를 입력으로 기대하는데 우리는 그것을 계산하지 않았고, Canny 엣지를 넣으면 방법이 아니라 그 불일치를 재게 된다. 우리 조건과 데이터로 ControlNet을 학습시킨 것이 대응 통제이며, 그것은 수행하지 않았다.

4.8 손으로 그린 스케치

그림 7이 전이 결과다. 학습에 쓰인 적 없는 실제 얼굴 그림 40장에서, 입력 그림에 대한 구조 순응도는 0.5484, CLIP 점수는 23.43이다. FID는 보고하지 않는다. 40장은 안정적인 추정에 부족하고, 평가기가 값을 내는 대신 거부한다. 학습 도메인에서 크게 벗어난 일반 장면 그림 500장도 돌렸다. 구조 순응도는



그림 7: 손으로 그린 얼굴 스케치(홀수 열)와 모델이 만든 결과(짝수 열), 제로샷. 그림에는 차단 반경이 없으므로 모델이 그림 자체에서 구조 밀도를 읽어야 하며, 이미지별 최소-최대 정규화가 이를 가능하게 한다. 스캔 대부분은 상단에 보관용 파일명이 찍혀 있고 모델은 그것까지 다시 그린다. 주어진 조건을 문자 그대로 따른 것이다. 그 머를 넉넉히 덮도록 프레임 상단 20%(102행)를 통째로 제외하면 점수는 0.5398이 된다(-0.0086, 표준오차 0.32배). 즉 점수가 재는 것은 그 때가 아니다.

0.1714로 떨어지고 FFHQ 대비 FID는 285.91다. 모델이 그림은 따르지만 얼굴을 만들지 못한다. 얼굴 모델에서 예상되는 실패이며 생략하지 않고 보고한다.

그림에는 차단 반경이 없지만 작가가 줄 수 있다. 그림을 r 로 걸러 모델에 넣으면 되고, 이는 모든 학습 조건이 거친 연산과 같다. 얼굴 그림 40장에서 원래 그림에 대한 구조 순응도는 $r=0$ 의 0.5486에서 $r=0.1$ 의 0.3390, $r=0.3$ 의 0.2271, $r=1$ 의 0.0407로 떨어진다. 다이얼이 그림에서도 작동한다. $r=0.5$ 와 $r=0.7$ 은 서로 표준오차(0.0419) 안에 있다. 실제로 받은 거른 그림에 대한 점수는 $r=0.1$ 에서 0.1399로, 거른 사진이 내는 0.6211보다 크게 낮다. 그 이유는 분리하지 않았다.

5 한계

쓸 만한 구간은 대략 $r \in [0, 0.3]$ 이다. 그 위에서는 조건에 남은 에너지가 적어 $r=0.5$ 에서 스펙트럼의 0.0014 — 구조 순응도를 해석하기 어려워진다. 거의 비어 있는 두 신호는 모델이 무엇을 하든 상관없이 0에 가깝기 때문이다.

여기 있는 모든 것은 한 도메인(FFHQ 얼굴)과 한 백본(SD1.5)이며, 세 결과는 옮겨가는 방식이 다르다. 다이얼은 조건의 성질이라 백본에 의존할 이유가 없지만 다른 백본에서 시험하지 않았다. skip 경로 주입은 그대로는 옮겨가지 않는다. MMDiT 백본 [1]에는 UNet식 skip 연결이 없고, 거기서 제어는 공유 토큰이나 LoRA [8] 모듈 [16, 31, 39]로 들어간다. VAE 측정은 4채널 SD 오토인코더에서만 했다. 우리 어댑터는 요즘 기준으로 작지도 않다. Simple-ControlNet [2]은 SD1.5에서 300만 미만, ControlNet-XS [36]는 ControlNet보다 훨씬 작은 제어 네트워크를 보고하고, 위의 DiT 모듈들은 우리의 몇 분의 일을 쓴다.

표 3의 어블레이션은 단일 시드다. 특화 모델 비교는 정직하지만 $r=0.1$ 에서 불리하고, 사용자 연구는 수행하지 않았다.

6 결론

학습 중 구조 조건의 대역폭을 무작위화하면 차단 반경이 추론 시 제어가 되고, 그 제어는 어댑터를 약하게 만드는 것으로 재현되지 않는다. 여기에 도달하려면 조건이 네트워크에 들어가는 위치를 고치고 조건을 동결 오토인코더 밖에 두어야 했다. 두 발견은 SD1.5의 오토인코더와 UNet에서 측정된 것이며, 같은 계열 위의 조건화 설계에는 옮겨가리라

본다. 다른 계열은 시험하지 않았다.

References

- [1] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling rectified flow transformers for high-resolution image synthesis. *arXiv:2403.03206*, 2024. URL <https://arxiv.org/abs/2403.03206>.
- [2] Zhida Feng, Li Chen, Yuenan Sun, Jiaxiang Liu, and Shikun Feng. Simplifying control mechanism in text-to-image diffusion models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 3013–3021, 2025. doi: 10.1609/aaai.v39i3.32309. URL <https://doi.org/10.1609/aaai.v39i3.32309>.
- [3] Tiankai Hang, Shuyang Gu, Chen Li, Jianmin Bao, Dong Chen, Han Hu, Xin Geng, and Baining Guo. Efficient diffusion training via min-snr weighting strategy. *arXiv:2303.09556*, 2023. URL <https://arxiv.org/abs/2303.09556>.
- [4] Yinxi He, Kang Liao, Chunyu Lin, Tianyi Wei, and Yao Zhao. Structdiff: A structure-preserving and spatially controllable diffusion model for single-image generation. *arXiv:2604.12575*, 2026. URL <https://arxiv.org/abs/2604.12575>.
- [5] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. Gans trained by a two time-scale update rule converge to a local nash equilibrium. *arXiv:1706.08500*, 2017. URL <https://arxiv.org/abs/1706.08500>.
- [6] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv:2207.12598*, 2022. URL <https://arxiv.org/abs/2207.12598>.
- [7] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *arXiv:2006.11239*, 2020. URL <https://arxiv.org/abs/2006.11239>.
- [8] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv:2106.09685*, 2021. URL <https://arxiv.org/abs/2106.09685>.
- [9] Chao Huang, Susan Liang, Yunlong Tang, Jing Bi, Li Ma, Yapeng Tian, and Chenliang Xu. Fresca: Scaling in frequency space enhances diffusion models. *arXiv:2504.02154*, 2025. URL <https://arxiv.org/abs/2504.02154>.
- [10] Sida Huang, Siqu Huang, Ping Luo, and Hongyuan Zhang. Laytrol: Preserving pretrained knowledge in layout control for multimodal diffusion transformers. *arXiv:2511.07934*, 2025. URL <https://arxiv.org/abs/2511.07934>.
- [11] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. *arXiv:1812.04948*, 2018. URL <https://arxiv.org/abs/1812.04948>.
- [12] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. *arXiv:2201.12086*, 2022. URL <https://arxiv.org/abs/2201.12086>.
- [13] Ming Li, Taojiannan Yang, Huafeng Kuang, Jie Wu, Zhaoning Wang, Xuefeng Xiao, and Chen Chen. Controlnet++: Improving conditional controls with efficient consistency feedback. *arXiv:2404.07987*, 2024. URL <https://arxiv.org/abs/2404.07987>.
- [14] Yuheng Li, Haotian Liu, Qingyang Wu, Fangzhou Mu, Jianwei Yang, Jianfeng Gao, Chunyuan Li, and Yong Jae Lee. Gligen: Open-set grounded text-to-image generation. *arXiv:2301.07093*, 2023. URL <https://arxiv.org/abs/2301.07093>.
- [15] Xin Lin, Haodong Li, Zhifei Zhang, Yutong Yang, Haitian Zheng, Juanxi Tian, Zhe Lin, and Truong Nguyen. Pixelcontrol: Fine-grained condition fidelity in text-to-image diffusion. *arXiv:2608.15705*, 2026. URL <https://arxiv.org/abs/2608.15705>.
- [16] Shanyuan Liu, Jian Zhu, Junda Lu, Yue Gong, Li-uzhuozheng Li, Bo Cheng, Yuhang Ma, Liebuchu Wu, Xiaoyu Wu, Dawei Leng, and Yuhui Yin. Nanocontrol: A lightweight framework for precise and efficient control in diffusion transformer. *arXiv:2508.10424*, 2025. URL <https://arxiv.org/abs/2508.10424>.
- [17] Zehong Ma, Longhui Wei, Shuai Wang, Shiliang Zhang, and Qi Tian. Deco: Frequency-decoupled pixel diffusion for end-to-end image generation. *arXiv:2511.19365*, 2025. URL <https://arxiv.org/abs/2511.19365>.
- [18] Chong Mou, Xintao Wang, Liangbin Xie, Yanze Wu, Jian Zhang, Zhongang Qi, Ying Shan, and Xiao-hu Qie. T2i-adapter: Learning adapters to dig out more controllable ability for text-to-image diffusion models. *arXiv:2302.08453*, 2023. URL <https://arxiv.org/abs/2302.08453>.
- [19] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever, and Mark Chen. Glide: Towards photorealistic image generation and editing with text-guided diffusion models. *arXiv:2112.10741*, 2021. URL <https://arxiv.org/abs/2112.10741>.

- [20] Gaurav Parmar, Richard Zhang, and Jun-Yan Zhu. On aliased resizing and surprising subtleties in gan evaluation. *arXiv:2104.11222*, 2021. URL <https://arxiv.org/abs/2104.11222>.
- [21] William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv:2212.09748*, 2022. URL <https://arxiv.org/abs/2212.09748>.
- [22] Bohao Peng, Jian Wang, Yuechen Zhang, Wenbo Li, Ming-Chang Yang, and Jiaya Jia. Controlnext: Powerful and efficient control for image and video generation. *arXiv:2408.06070*, 2024. URL <https://arxiv.org/abs/2408.06070>.
- [23] Dustin Podell, Zion English, Kyle Lacey, Andreas Blattmann, Tim Dockhorn, Jonas Müller, Joe Penna, and Robin Rombach. Sdxl: Improving latent diffusion models for high-resolution image synthesis. *arXiv:2307.01952*, 2023. URL <https://arxiv.org/abs/2307.01952>.
- [24] Arisha Prasain. Beyond edge maps: Wavelet-domain conditioning for multi-adapter map-to-satellite diffusion. *arXiv:2608.00083*, 2026. URL <https://arxiv.org/abs/2608.00083>.
- [25] Can Qin, Shu Zhang, Ning Yu, Yihao Feng, Xinyi Yang, Yingbo Zhou, Huan Wang, Juan Carlos Niebles, Caiming Xiong, Silvio Savarese, Stefano Ermon, Yun Fu, and Ran Xu. Unicontrol: A unified diffusion model for controllable visual generation in the wild. *arXiv:2305.11147*, 2023. URL <https://arxiv.org/abs/2305.11147>.
- [26] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. *arXiv:2103.00020*, 2021. URL <https://arxiv.org/abs/2103.00020>.
- [27] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. *arXiv:2112.10752*, 2021. URL <https://arxiv.org/abs/2112.10752>.
- [28] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S. Sara Mahdavi, Rapha Gontijo Lopes, Tim Salimans, Jonathan Ho, David J Fleet, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. *arXiv:2205.11487*, 2022. URL <https://arxiv.org/abs/2205.11487>.
- [29] Chenyang Si, Ziqi Huang, Yuming Jiang, and Ziwei Liu. Freeu: Free lunch in diffusion u-net. *arXiv:2309.11497*, 2023. URL <https://arxiv.org/abs/2309.11497>.
- [30] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv:2010.02502*, 2020. URL <https://arxiv.org/abs/2010.02502>.
- [31] Zhenxiong Tan, Songhua Liu, Xingyi Yang, Qiaochu Xue, and Xinchao Wang. Ominicontrol: Minimal and universal control for diffusion transformer. *arXiv:2411.15098*, 2024. URL <https://arxiv.org/abs/2411.15098>.
- [32] Gabriel Tjio, Jie Zhang, Xulei Yang, Yun Xing, Nhat Chung, Xiaofeng Cao, Ivor W. Tsang, Chee Keong Kwok, and Qing Guo. Focus: Frequency-optimized conditioning of diffusion models for mitigating catastrophic forgetting during test-time adaptation. *arXiv:2508.14437*, 2025. URL <https://arxiv.org/abs/2508.14437>.
- [33] Yifeng Xu, Zhenliang He, Shiguang Shan, and Xilin Chen. Ctrlora: An extensible and efficient framework for controllable image generation. *arXiv:2410.09400*, 2024. URL <https://arxiv.org/abs/2410.09400>.
- [34] Hu Ye, Jun Zhang, Sibio Liu, Xiao Han, and Wei Yang. Ip-adapter: Text compatible image prompt adapter for text-to-image diffusion models. *arXiv:2308.06721*, 2023. URL <https://arxiv.org/abs/2308.06721>.
- [35] Bo Yin, Xiaobin Hu, Xingyu Zhou, Yu He, Peng-Tao Jiang, Yue Liao, Junwei Zhu, Jiangning Zhang, Ying Tai, and Shuicheng Yan. Fera: Frequency-energy constrained routing for effective diffusion adaptation fine-tuning. *arXiv:2511.17979*, 2025. URL <https://arxiv.org/abs/2511.17979>.
- [36] Denis Zavadski, Johann-Friedrich Feiden, and Carsten Rother. Controlnet-xs: Rethinking the control of text-to-image diffusion models as feedback-control systems. *arXiv:2312.06573*, 2023. URL <https://arxiv.org/abs/2312.06573>.
- [37] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. *arXiv:2302.05543*, 2023. URL <https://arxiv.org/abs/2302.05543>.
- [38] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. *arXiv:1801.03924*, 2018. URL <https://arxiv.org/abs/1801.03924>.
- [39] Yuxuan Zhang, Yirui Yuan, Yiren Song, Haofan Wang, and Jiaming Liu. Easycontrol: Adding efficient and flexible control for diffusion transformer. *arXiv:2503.07027*, 2025. URL <https://arxiv.org/abs/2503.07027>.
- [40] Shihao Zhao, Dongdong Chen, Yen-Chun Chen, Jianmin Bao, Shaozhe Hao, Lu Yuan,

and Kwan-Yee K. Wong. Uni-controlnet: All-in-one control to text-to-image diffusion models. *arXiv:2305.16322*, 2023. URL <https://arxiv.org/abs/2305.16322>.

- [41] Chao Zhou, Tianyi Wei, Yiling Chen, Wenbo Zhou, and Nenghai Yu. Rethinking multi-condition dits: Eliminating redundant attention via position-alignment and keyword-scoping. *arXiv:2602.06850*, 2026. URL <https://arxiv.org/abs/2602.06850>.